HURTOWNIE DANYCH

1. Tytuł projektu

Podróże samolotem

2. Charakterystyka dziedziny problemowej

2.1 Opis obszaru analizy (wybrany fragment dziedziny, przeznaczony do szczegółowej analizy i opracowania hurtowni danych)

Analiza będzie obejmowała dane dotyczące lotów w tym miejsc noclegowych (hoteli). Dzięki niej będzie można dowiedzieć się dokąd najczęściej odbywają się podróże samolotem, jakim przewoźnikiem i jaką klasą oraz w jakich hotelach najczęściej odpoczywają podróżujący. Dzięki przeprowadzonej analizie przewoźnicy będą maksymalizować zyski i minimalizować straty.

2.2 Problemy

P01 – Odwoływanie lotów

P02 – Częste strajki personelu lotniczego

P03 – Brak możliwości doboru klasy przewoźnika

2.3 Cel przedsięwzięcia

2.3.1 Oczekiwania i potrzeby w zakresie wsparcia podejmowania decyzji

- Dokąd najczęściej odbywają się podróże?
- Jakim przewoźnikiem odbywa się lot?
- Jaka jest klasa miejsca w czasie lotu?
- W jakich hotelach odpoczywają podróżujący?

- Kiedy najczęściej odbywają się podróże?

2.3.2 Zakres analizy

Badane aspekty

1. Dokąd oraz kiedy najczęściej odbywają się podróże samolotem?
2. Jakim przewoźnikiem i jaką klasą odbywają się podróże?
3. W jakich hotelach najczęściej odpoczywają podróżujący?

Pytania badawcze

1. Dokąd najczęściej odbywają się podróże?
2. Jakim przewoźnikiem odbywa się lot?
3. Jaka jest klasa miejsca w czasie lotu?
4. W jakich hotelach odpoczywają podróżujący?
5. Kiedy najczęściej odbywają się podróże?

2.3.3 Potencjalni użytkownicy

Pracownicy firm przewoźnika i biur podróży (np. analitycy)

3. Dane źródłowe

3.1. Źródła danych

Charakterystyka pliku zawierający danę źródłowe przeznaczone do stworzenia tematycznej hurtowni danych jest przedstawiona w tab. 1.

Tabela 1. Zbiory danych źródłowych

Lp.	Plik	Typ	Liczba rek.	Rozmiar[MB]	Opis
1.	flights.csv	csv	271888	24.57	Dane lotów
2.	hotels.csv	csv	40552	2.51	Dane zakwaterowań w hotelach
3.	users.csv	csv	1340	0.05172	Dane podróżujących

3.2. Lokalizacja, dostępność danych źródłowych

Dane są darmowe i pochodzą ze strony https://www.kaggle.com/datasets/leomauro/argodatathon2019/versions/1?resource=download

3.3. Słownik danych – interpretacja

Interpretacja oraz wyjaśnienie znaczeń pojęć dziedzinowych zostały zawarte w tab.2.

Tabela 2. Słownik atrybutów

Plik: flights.csv				
Lp.	**Atrybut**	**Typ danych**	**Znaczenie**	**Uwagi**
1.	agency	Tekstowy	Nazwa agencji	Nazwa agencji Poprawne dane
2.	date	Data	Data lotu	Data lotu, format MM/DD/RRRR Poprawne dane
3.	distance	Numeryczny	Dystans lotu	Dystans lotu Poprawne dane
4.	flightType	Tekstowy	Klasa lotu	Klasa lotu Poprawne dane
5.	from	Tekstowy	Miejsce, od którego zaczyna się podróż	Miejsce, od którego zaczyna się podróż Poprawne dane
6.	price	Numeryczny	Cena lotu	Cena lotu Poprawne dane
7.	time	Numeryczny	Czas lotu	Czas lotu Poprawne dane
8.	to	Tekstowy	Miejsce, w którym kończy się podróż	Miejsce, w którym kończy się podróż Poprawne dane

9.	travelCode	Numeryczny	Kod podróży	Kod podróży Poprawne dane
10.	userCode	Numeryczny	Kod podróżującego/gościa	Kod podróżującego/gościa Poprawne dane

Plik: hotels.csv				
Lp.	**Atrybut**	**Typ danych**	**Znaczenie**	**Uwagi**
1.	travelCode	Numeryczny	Kod podróży	Kod podróży Poprawne dane
2.	userCode	Numeryczny	Kod podróżującego/ gościa	Kod podróżującego/gościa Poprawne dane
3.	name	Tekstowy	Nazwa hotelu	Nazwa hotelu Poprawne dane
4.	place	Tekstowy	Nazwa miejsca, w którym jest hotel	Nazwa miejsca, w którym jest hotel Poprawne dane
5.	days	Numeryczny	Liczba dni pobytu	Liczba dni pobytu Poprawne dane
6.	price	Numeryczny	Cena za dobę hotelową	Cena za dobę hotelową Poprawne dane
7.	total	Numeryczny	Łączny koszt pobytu	Łączny koszt pobytu Poprawne dane
8.	date	Data	Data pobytu	Data pobytu Poprawne dane

Plik: users.csv				
Lp.	**Atrybut**	**Typ danych**	**Znaczenie**	**Uwagi**
1.	code	Numeryczny	Kod podróżującego /gościa	Kod podróżującego/gościa Poprawne dane
2.	company	Tekstowy	Firma podróżującego /gościa	Firma podróżującego/gościa Poprawne dane
3.	name	Tekstowy	Imię i nazwisko podróżującego /gościa	Imię i nazwisko podróżującego/gościa Poprawne dane
4.	gender	Tekstowy	Płeć podróżującego /gościa	Płeć podróżującego/gościa Poprawne dane
5.	age	Numeryczny	Wiek gościa	Wiek gościa Poprawne dane

3.4. Ocena jakościowa danych

Wynik analizy jakościowej przeprowadzonej za pomocą programu Tableau oraz profilu danych SSIS został przedstawiony w tab. 3.

Tabela 3. Ocena jakościowa danych

Plik: flights.csv					
Lp.	**Atrybut**	**Typ danych**	**Zakres wartości**	**Znaczenie**	**Uwagi - ocena jakości danych**
1.	travelCode	Numeryczny	0-135943	Kod podróży	Kod podróży Poprawne dane

2.	userCode	Numeryczny	0-1339	Kod podróżującego/gościa	Kod podróżującego/gościa Poprawne dane
3.	from	Tekstowy		Miejsce, od którego zaczyna się podróż	Miejsce, od którego zaczyna się podróż Poprawne dane
4.	to	Tekstowy		Miejsce, w którym kończy się podróż	Miejsce, w którym kończy się podróż Poprawne dane
5.	flightType	Tekstowy	{economic, firstClass, premium}	Klasa lotu	Klasa lotu Poprawne dane
6.	price	Numeryczny	301,51-1754,17	Cena lotu	Cena lotu Poprawne dane
7.	time	Numeryczny	0,44-2,44	Czas lotu	Czas lotu Poprawne dane
8.	distance	Numeryczny	168,22-937,77	Dystans lotu	Dystans lotu Poprawne dane
9.	agency	Tekstowy		Nazwa agencji	Nazwa agencji Poprawne dane
10.	date	Data	09/26/2019-07/24/2023	Data lotu	Data lotu, format MM/DD/RRRR Poprawne dane
Plik: hotels.csv					
Lp.	**Atrybut**	**Typ danych**	**Zakres wartości**	**Znaczenie**	**Uwagi - ocena jakości danych**
1.	travelCode	Numeryczny	0-135943	Kod podróży	Kod podróży

					Poprawne dane
2.	userCode	Numeryczny	0-1339	Kod podróżującego/gościa	Kod podróżującego/gościa Poprawne dane
3.	name	Tekstowy		Nazwa hotelu	Nazwa hotelu Poprawne dane
4.	place	Tekstowy		Nazwa miejsca, w którym jest hotel	Nazwa miejsca, w którym jest hotel Poprawne dane
5.	days	Numeryczny	{1, 2, 3, 4 }	Liczba dni pobytu	Liczba dni pobytu Poprawne dane
6.	price	Numeryczny	60,39 – 313,02	Cena za dobę hotelową	Cena za dobę hotelową Poprawne dane
7.	total	Numeryczny	60,39 – 1252,08	Łączny koszt pobytu	Łączny koszt pobytu Poprawne dane
8.	date	Data	09/26/2019 – 07/13/2023	Data pobytu	Data pobytu Poprawne dane
Plik: users.csv					
Lp.	**Atrybut**	**Typ danych**	**Zakres wartości**	**Znaczenie**	**Uwagi - ocena jakości danych**
1.	code	Numeryczny	0-1339	Kod podróżującego/gościa	Kod podróżującego/gościa Poprawne dane
2.	company	Tekstowy		Firma podróżującego/gościa	Firma podróżującego/gościa Poprawne dane

3.	name	Tekstowy		Imię i nazwisko podróżującego/gościa	Imię i nazwisko podróżującego/gościa Poprawne dane
4.	gender	Tekstowy	{male, female}	Płeć podróżującego/gościa	Płeć podróżującego/gościa Poprawne dane
5.	age	Numeryczny	21-65	Wiek gościa	Wiek gościa Poprawne dane

4. Analityczne modele wielowymiarowe

4.1. Fakty **podlegające analizie oraz ich miary**

Analizie będzie podlegał zbiór zarejestrowanych zdarzeń (tab. 4.)

Tabela 4. Fakty podlegające analizie

Lp.	Fakty	Miary	Uwagi
1.	Przelot	Dystans, czas, cena	W Visualu to Przelot
2.	Pobyt w hotelu	Liczba dni, cena za dzień, cena całkowita	W Visualu to Pobyt_w_hotelu

4.2. Kontekst analizy faktów

Ustalony kontekst analizy faktów został przedstawiony w tab. 5.

Tabela 5. Wymiary analizy faktów

Lp.	Wymiar	Własności
1.	Miejsce	Nazwa
2.	Lot_samolotem	Klasa lotu, przewoźnik
3.	Podróżujący	Płeć, wiek, imię i nazwisko, firma

4.	Hotel	Miejsce, nazwa, *liczba gwiazdek, czy jest all-inclusive*
5.	Time	Data, rok, półrocze, kwartał, miesiąc, tydzień, dzień roku, dzień półrocza, dzień kwartału, dzień miesiąca, dzień tygodnia, tydzień roku, miesiąc roku, miesiąc półrocza, miesiąc kwartału, kwartał roku, kwartał półrocza, półrocze roku

Własności pisanych czcionką pochyłą nie da się uwzględnić ze względu na brak danych.

4.3. Modele wielowymiarowe (UML)

Po przeanalizowaniu atrybutów źródła danych oraz ustalonego faktu i kontekstu analizy zaproponowano wielowymiarowy model konceptualny (rys. 1.). Składa się on z faktów Przelot i Pobyt w hotelu oraz 5 wymiarów. Model ten reprezentowany jest w postaci schematu płatka śniegu.

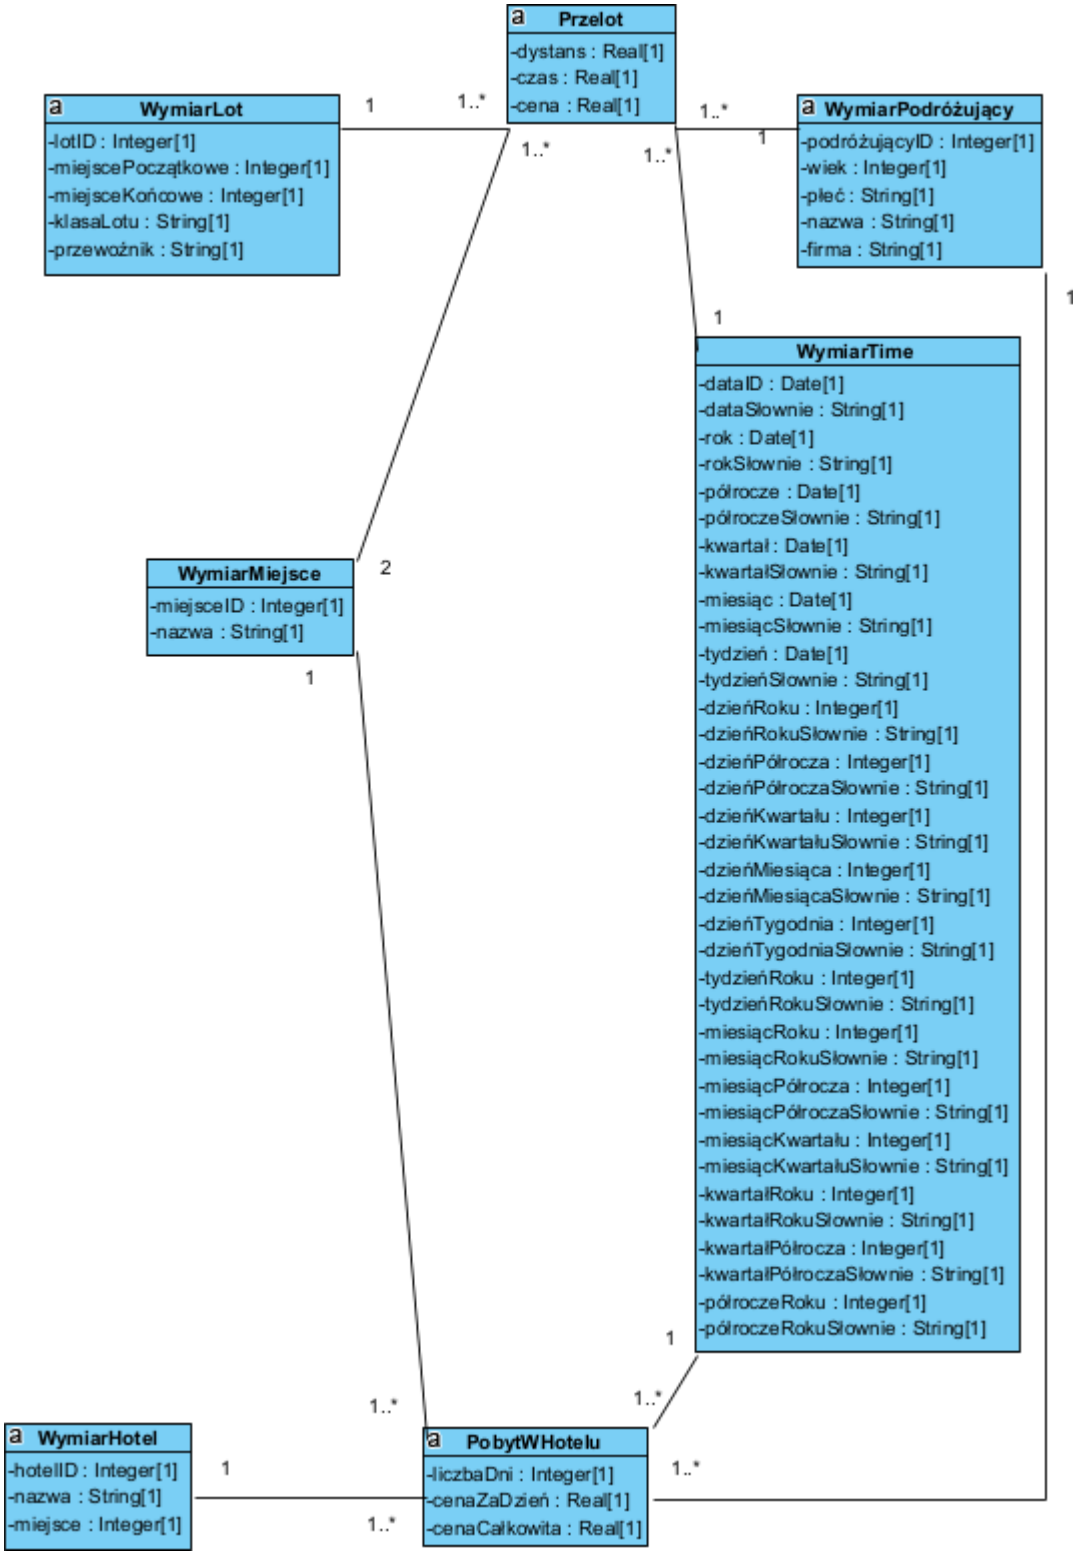
Przelot
-dystans : Real[1]
-czas : Real[1]
-cena : Real[1]
WymiarLot
-lotID : Integer[1]
-miejscePoczątkowe : Integer[1]
-miejsceKońcowe : Integer[1]
-klasaLotu : String[1]
-przewoźnik : String[1]
WymiarPodróżujący
-podróżującyID : Integer[1]
-wiek : Integer[1]
-płeć : String[1]
-nazwa : String[1]
-firma : String[1]
WymiarTime
-dataID : Date[1]
-dataSłownie : String[1]
-rok : Date[1]
-rokSłownie : String[1]
-półrocze : Date[1]
-półroczeSłownie : String[1]
-kwartał : Date[1]
-kwartałSłownie : String[1]
-miesiąc : Date[1]
-miesiącSłownie : String[1]
-tydzień : Date[1]
-tydzieńSłownie : String[1]
-dzieńRoku : Integer[1]
-dzieńRokuSłownie : String[1]
-dzieńPółrocza : Integer[1]
-dzieńPółroczaSłownie : String[1]
-dzieńKwartału : Integer[1]
-dzieńKwartałuSłownie : String[1]
-dzieńMiesiąca : Integer[1]
-dzieńMiesiącaSłownie : String[1]
-dzieńTygodnia : Integer[1]
-dzieńTygodniaSłownie : String[1]
-tydzieńRoku : Integer[1]
-tydzieńRokuSłownie : String[1]
-miesiącRoku : Integer[1]
-miesiącRokuSłownie : String[1]
-miesiącPółrocza : Integer[1]
-miesiącPółroczaSłownie : String[1]
-miesiącKwartału : Integer[1]
-miesiącKwartałuSłownie : String[1]
-kwartałRoku : Integer[1]
-kwartałRokuSłownie : String[1]
-kwartałPółrocza : Integer[1]
-kwartałPółroczaSłownie : String[1]
-półroczeRoku : Integer[1]
-półroczeRokuSłownie : String[1]
WymiarMiejsce
-miejsceID : Integer[1]
-nazwa : String[1]
WymiarHotel
-hotelID : Integer[1]
-nazwa : String[1]
-miejsce : Integer[1]
PobytWHotelu
-liczbaDni : Integer[1]
-cenaZaDzień : Real[1]
-cenaCałkowita : Real[1]
1
1..*
1..*
1..*
1..*
1
1
1
2
1
1..*
1..*
1
1..*
1..*

Rysunek 1. Wielowymiarowy model analityczny przedstawiony na poziomie konceptualnym

5. Projekt procesu ETL

5.1. Schemat bazy danych HD (skrypt SQL)

Baza danych została utworzona za pomocą skryptu przedstawionego w tabeli 6.

Tabela 6. Skrypt SQL tworzenia bazy hurtowni danych

```
CREATE TABLE [dbo].[Time](
	[PK_Date] [datetime] NOT NULL,
	[Date_Name] [nvarchar](50) NULL,
	[Year] [datetime] NULL,
	[Year_Name] [nvarchar](50) NULL,
	[Half_Year] [datetime] NULL,
	[Half_Year_Name] [nvarchar](50) NULL,
	[Quarter] [datetime] NULL,
	[Quarter_Name] [nvarchar](50) NULL,
	[Month] [datetime] NULL,
	[Month_Name] [nvarchar](50) NULL,
	[Week] [datetime] NULL,
	[Week_Name] [nvarchar](50) NULL,
	[Day_Of_Year] [int] NULL,
	[Day_Of_Year_Name] [nvarchar](50) NULL,
	[Day_Of_Half_Year] [int] NULL,
	[Day_Of_Half_Year_Name] [nvarchar](50) NULL,
	[Day_Of_Quarter] [int] NULL,
	[Day_Of_Quarter_Name] [nvarchar](50) NULL,
	[Day_Of_Month] [int] NULL,
	[Day_Of_Month_Name] [nvarchar](50) NULL,
	[Day_Of_Week] [int] NULL,
	[Day_Of_Week_Name] [nvarchar](50) NULL,
	[Week_Of_Year] [int] NULL,
	[Week_Of_Year_Name] [nvarchar](50) NULL,
	[Month_Of_Year] [int] NULL,
	[Month_Of_Year_Name] [nvarchar](50) NULL,
	[Month_Of_Half_Year] [int] NULL,
	[Month_Of_Half_Year_Name] [nvarchar](50) NULL,
	[Month_Of_Quarter] [int] NULL,
	[Month_Of_Quarter_Name] [nvarchar](50) NULL,
	[Quarter_Of_Year] [int] NULL,
	[Quarter_Of_Year_Name] [nvarchar](50) NULL,
	[Quarter_Of_Half_Year] [int] NULL,
	[Quarter_Of_Half_Year_Name] [nvarchar](50) NULL,
	[Half_Year_Of_Year] [int] NULL,
	[Half_Year_Of_Year_Name] [nvarchar](50) NULL,
 CONSTRAINT [PK_Time] PRIMARY KEY CLUSTERED
(
	[PK_Date] ASC
)WITH (PAD_INDEX = OFF, STATISTICS_NORECOMPUTE = OFF,
```

```
	IGNORE_DUP_KEY = OFF, ALLOW_ROW_LOCKS = ON,
	ALLOW_PAGE_LOCKS = ON, OPTIMIZE_FOR_SEQUENTIAL_KEY = OFF) ON [PRIMARY]
) ON [PRIMARY]


CREATE TABLE [dbo].[Podróżujący](
	[PK_Podróżujący] [int] NOT NULL,
	[firma] [nvarchar](50) NULL,
	[nazwa] [nvarchar](50) NULL,
	[płeć] [nvarchar](50) NULL,
	[wiek] [nvarchar](50) NULL,
 CONSTRAINT [PK_Podróżujący] PRIMARY KEY CLUSTERED
(
	[PK_Podróżujący] ASC
)WITH (PAD_INDEX = OFF, STATISTICS_NORECOMPUTE = OFF,
	IGNORE_DUP_KEY = OFF, ALLOW_ROW_LOCKS = ON,
	ALLOW_PAGE_LOCKS = ON, OPTIMIZE_FOR_SEQUENTIAL_KEY = OFF) ON [PRIMARY]
) ON [PRIMARY]




CREATE TABLE [dbo].[Miejsce](
	[PK_Miejsce] [int] NOT NULL,
	[Nazwa] [nvarchar](50) NULL,
 CONSTRAINT [PK_Miejsce] PRIMARY KEY CLUSTERED
(
	[PK_Miejsce] ASC
)WITH (PAD_INDEX = OFF, STATISTICS_NORECOMPUTE = OFF,
	IGNORE_DUP_KEY = OFF, ALLOW_ROW_LOCKS = ON,
	ALLOW_PAGE_LOCKS = ON,
	OPTIMIZE_FOR_SEQUENTIAL_KEY = OFF) ON [PRIMARY]
) ON [PRIMARY]




CREATE TABLE [dbo].[Hotel](
	[PK_Hotel] [int] NOT NULL,
	[miejsce] [int] NULL,
	[nazwa] [nvarchar](50) NULL,
CONSTRAINT [PK_Hotel] PRIMARY KEY CLUSTERED
(
	[PK_Hotel] ASC
)WITH (PAD_INDEX = OFF, STATISTICS_NORECOMPUTE = OFF,
	IGNORE_DUP_KEY = OFF, ALLOW_ROW_LOCKS = ON,
	ALLOW_PAGE_LOCKS = ON,
	OPTIMIZE_FOR_SEQUENTIAL_KEY = OFF) ON [PRIMARY]
) ON [PRIMARY]




CREATE TABLE [dbo].[Pobyt_w_hotelu](
	[FK_Time] [datetime] NULL,
	[FK_Podróżujący] [int] NULL,
	[FK_Hotel] [int] NULL,
```

```
	[liczbaDni] [int] NULL,
	[cenaZaDzień] [money] NULL,
	[cenaCałkowita] [money] NULL,
) ON [PRIMARY]
GO

ALTER TABLE [dbo].[Pobyt_w_hotelu]
WITH CHECK
ADD  CONSTRAINT [Pobyt_w_hotelu-Hotel]
FOREIGN KEY([FK_Hotel])
REFERENCES [dbo].[Hotel] ([PK_Hotel])
GO

ALTER TABLE [dbo].[Pobyt_w_hotelu]
CHECK CONSTRAINT [Pobyt_w_hotelu-Hotel]
GO

ALTER TABLE [dbo].[Pobyt_w_hotelu]
WITH CHECK
ADD  CONSTRAINT [Pobyt_w_hotelu-Podróżujący]
FOREIGN KEY([FK_Podróżujący])
REFERENCES [dbo].[Podróżujący] ([PK_Podróżujący])
GO

ALTER TABLE [dbo].[Pobyt_w_hotelu]
CHECK CONSTRAINT [Pobyt_w_hotelu-Podróżujący]
GO

ALTER TABLE [dbo].[Pobyt_w_hotelu]
WITH CHECK ADD  CONSTRAINT [Pobyt_w_hotelu-Time]
FOREIGN KEY([FK_Time])
REFERENCES [dbo].[Time] ([PK_Date])
GO

ALTER TABLE [dbo].[Pobyt_w_hotelu]
CHECK CONSTRAINT [Pobyt_w_hotelu-Time]




CREATE TABLE [dbo].[Lot_samolotem](
	[PK_Lot_samolotem] [int] NOT NULL,
	[klasaLotu] [nvarchar](50) NULL,
	[miejscePoczątkowe] [int] NULL,
	[miejsceKońcowe] [int] NULL,
	[przewoźnik] [nvarchar](50) NULL,
 CONSTRAINT [PK_Lot_samolotem] PRIMARY KEY CLUSTERED
(
	[PK_Lot_samolotem] ASC
)WITH (PAD_INDEX = OFF, STATISTICS_NORECOMPUTE = OFF,
	IGNORE_DUP_KEY = OFF, ALLOW_ROW_LOCKS = ON,
	ALLOW_PAGE_LOCKS = ON,
	OPTIMIZE_FOR_SEQUENTIAL_KEY = OFF) ON [PRIMARY]
) ON [PRIMARY]
```

```sql
CREATE TABLE [dbo].[Przelot](
	[FK_Time] [datetime] NULL,
	[FK_Podróżujący] [int] NULL,
	[FK_Lot_samolotem] [int] NULL,
	[dystans] [real] NULL,
	[czas] [real] NULL,
	[cena] [money] NULL
) ON [PRIMARY]
GO

ALTER TABLE [dbo].[Przelot]
WITH CHECK
ADD CONSTRAINT [Przelot-Lot_samolotem]
FOREIGN KEY([FK_Lot_samolotem])
REFERENCES [dbo].[Lot_samolotem] ([PK_Lot_samolotem])
GO

ALTER TABLE [dbo].[Przelot]
CHECK CONSTRAINT [Przelot-Lot_samolotem]
GO

ALTER TABLE [dbo].[Przelot]
WITH CHECK ADD CONSTRAINT [Przelot-Podróżujący]
FOREIGN KEY([FK_Podróżujący])
REFERENCES [dbo].[Podróżujący] ([PK_Podróżujący])
GO

ALTER TABLE [dbo].[Przelot]
CHECK CONSTRAINT [Przelot-Podróżujący]
GO

ALTER TABLE [dbo].[Przelot]
WITH CHECK ADD CONSTRAINT [Przelot-Time]
FOREIGN KEY([FK_Time])
REFERENCES [dbo].[Time] ([PK_Date])
GO

ALTER TABLE [dbo].[Przelot]
CHECK CONSTRAINT [Przelot-Time]
```

Wygenerowany przez Microsoft SQL Server Management Studio schemat bazy został przedstawiony na rys. 2.

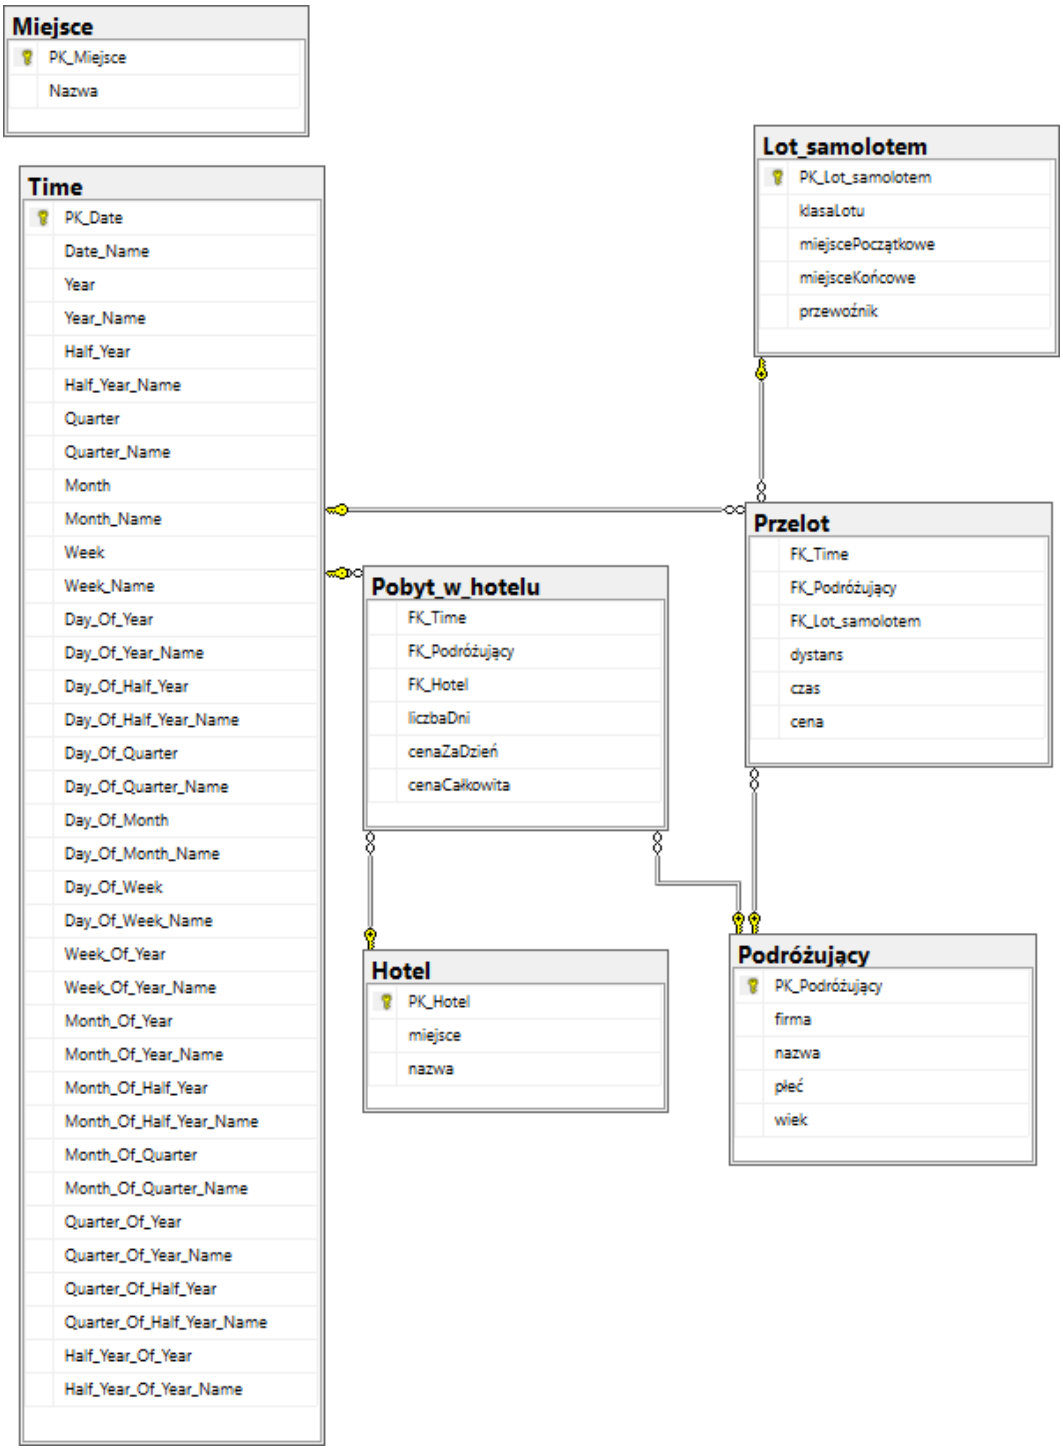

Rysunek 2. Schemat bazy danych utworzonej za pomocą skryptu (tab. 6.)

5.2. Specyfikacja procesów ETL (Control Flow + Data Flow)

Ten etl wczytuje informacje z plików csv. Dzięki ustawionym operacjom, kolejne procesy przekształcają za pośrednictwem tabel tymczasowych, wczytane informacje, dzięki czemu otrzymujemy funkcjonalną bazę danych.

Utworzony Control Flow został przedstawiony na rysunku 3.

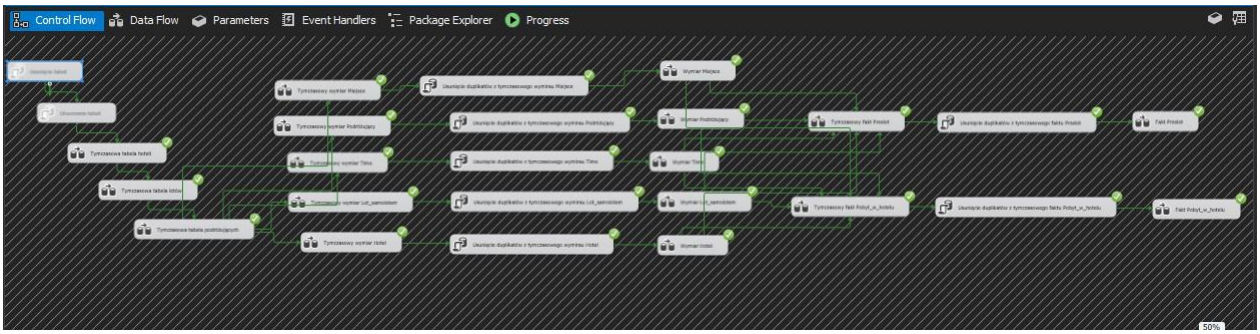

Rysunek 3. Control Flow

Utworzony Data Flow dla tymczasowej tabeli hoteli został przedstawiony na rysunku 4.

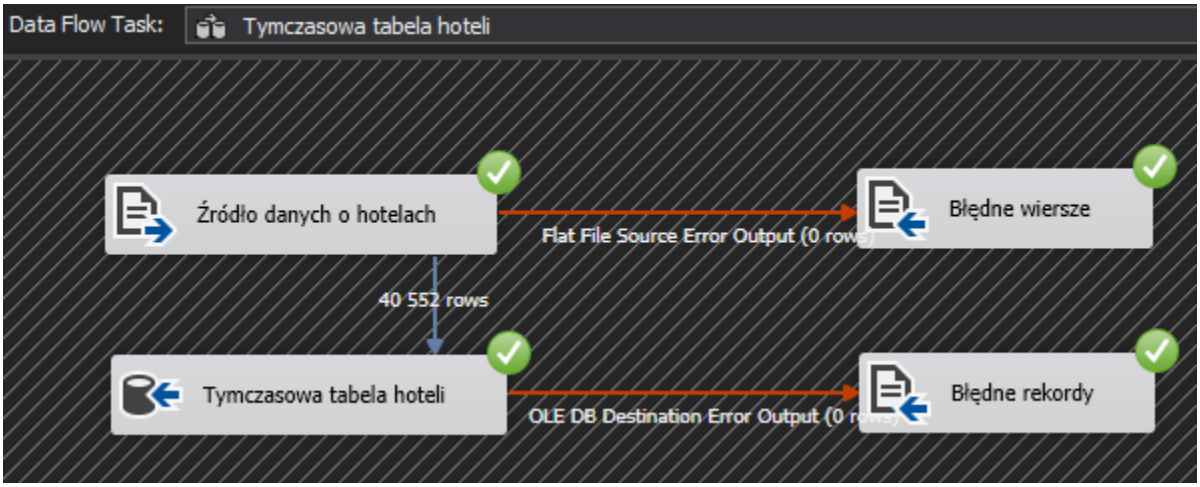

Rysunek 4. Data Flow dla tymczasowej tabeli hoteli

Analogicznie tworzy się Data Flow dla pozostałych tymczasowych tabel lotów i podróżujących.

Utworzony Data Flow dla tymczasowego wymiaru Miejsce został przedstawiony na rysunku 5.

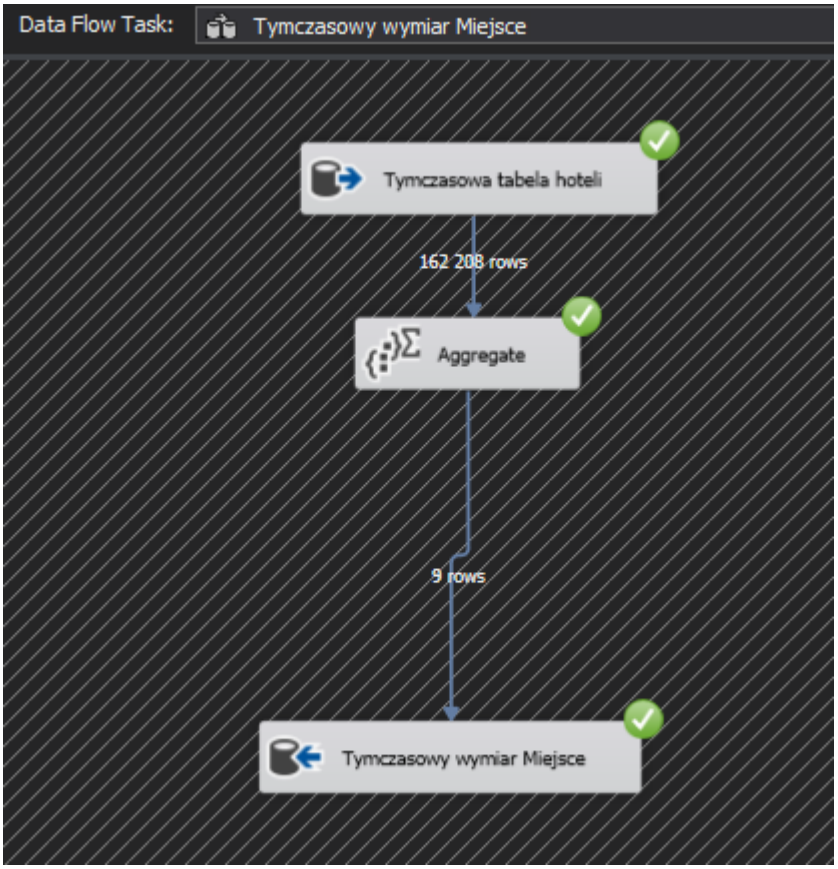

Rysunek 5. Data Flow dla tymczasowego wymiaru Miejsce

Utworzony Data Flow dla tymczasowego wymiaru Hotel został przedstawiony na rysunku 6.

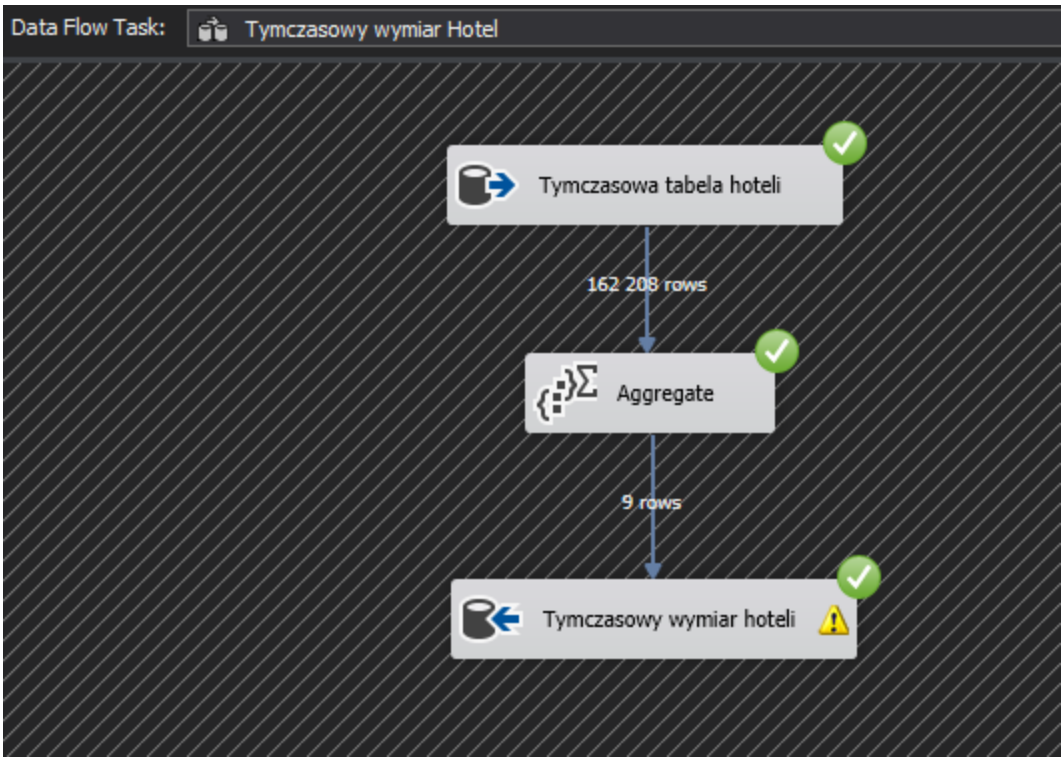

Rysunek 6. Data Flow dla tymczasowego wymiaru Hotel

Analogicznie tworzy się Data Flow dla tymczasowego wymiaru Lot_samolotem oraz tymczasowego wymiaru Podróżujący.

Utworzony Data Flow dla tymczasowego wymiaru Time został przedstawiony na rysunku 7.

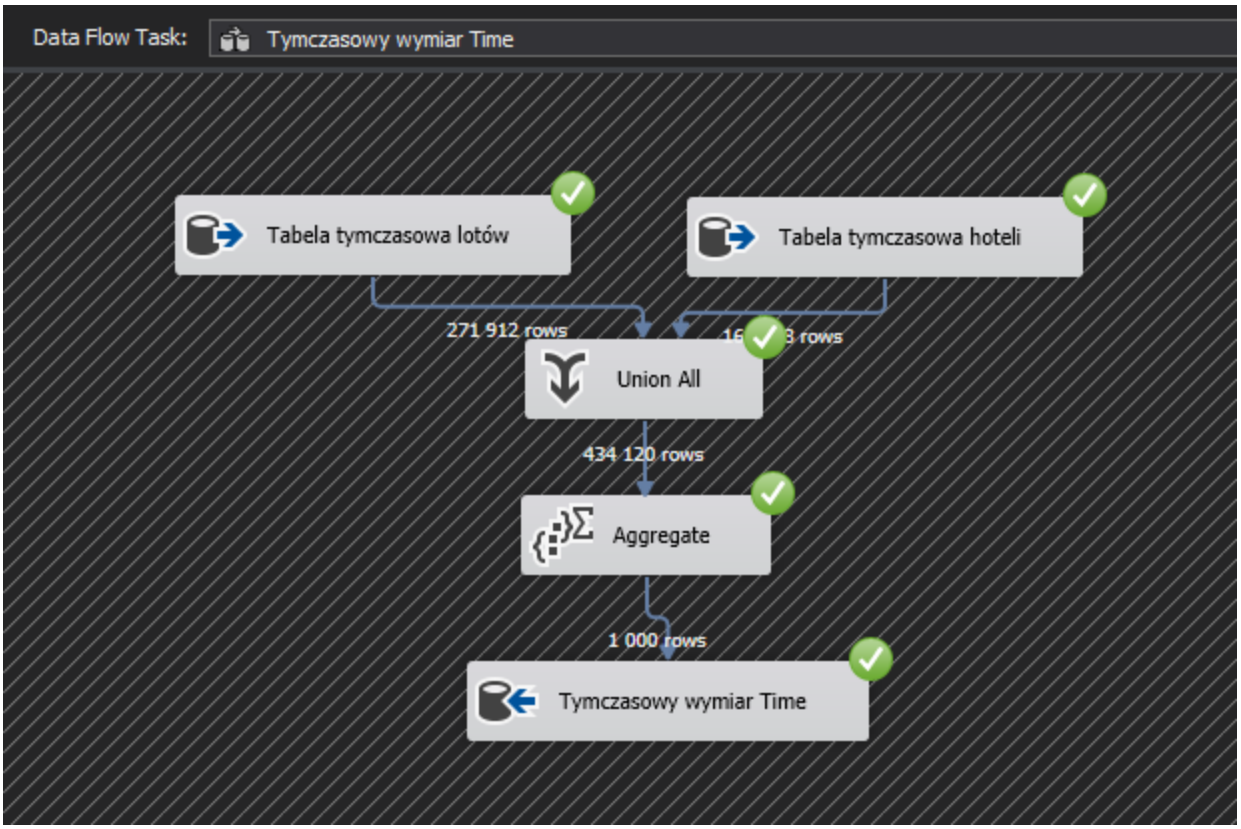

Rysunek 7. Data Flow dla tymczasowego wymiaru Time

Utworzony Data Flow dla wymiaru Hotel został przedstawiony na rysunku 8.

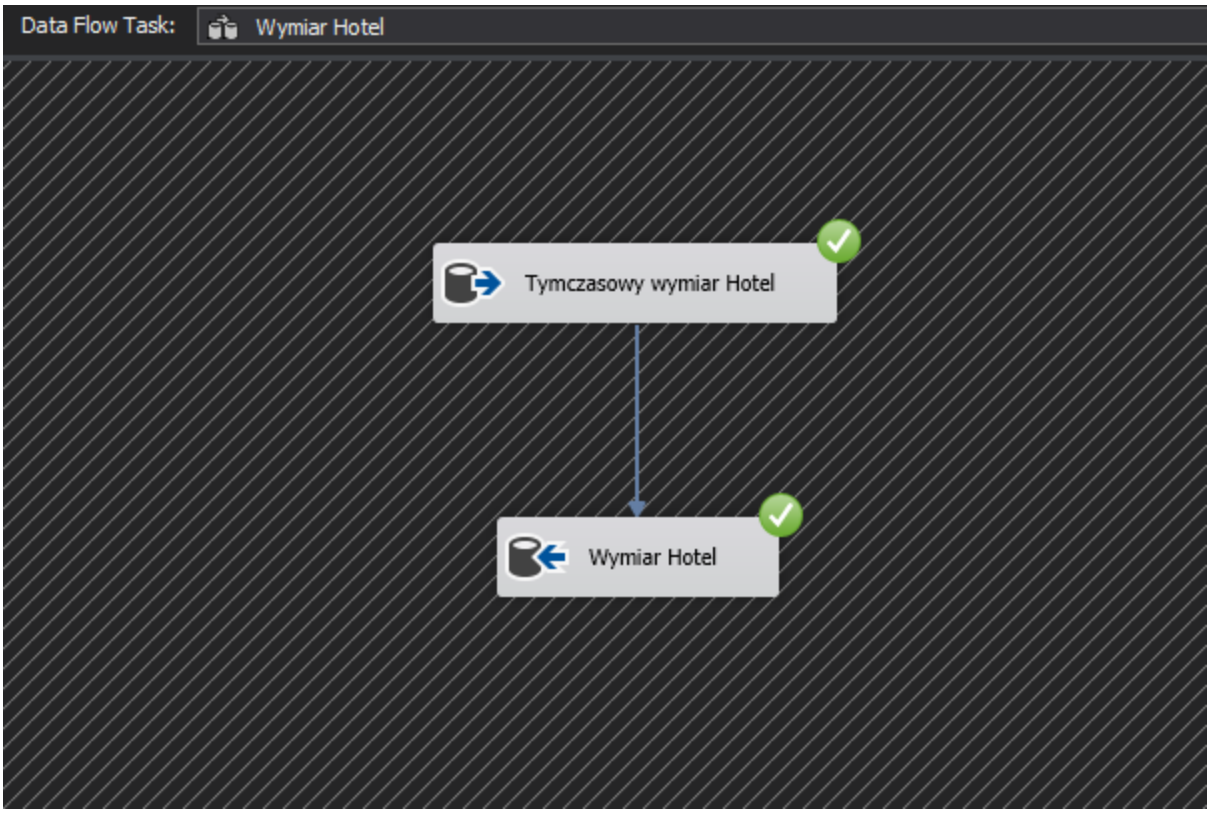

Rysunek 8. Data Flow dla wymiaru Hotel

Analogicznie tworzy się Data Flow dla wymiarów Podróżujący, Miejsce, Lot_samolotem, Time.

Utworzony Data Flow dla tymczasowego faktu Pobyt_w_hotelu został przedstawiony na rysunku 9.

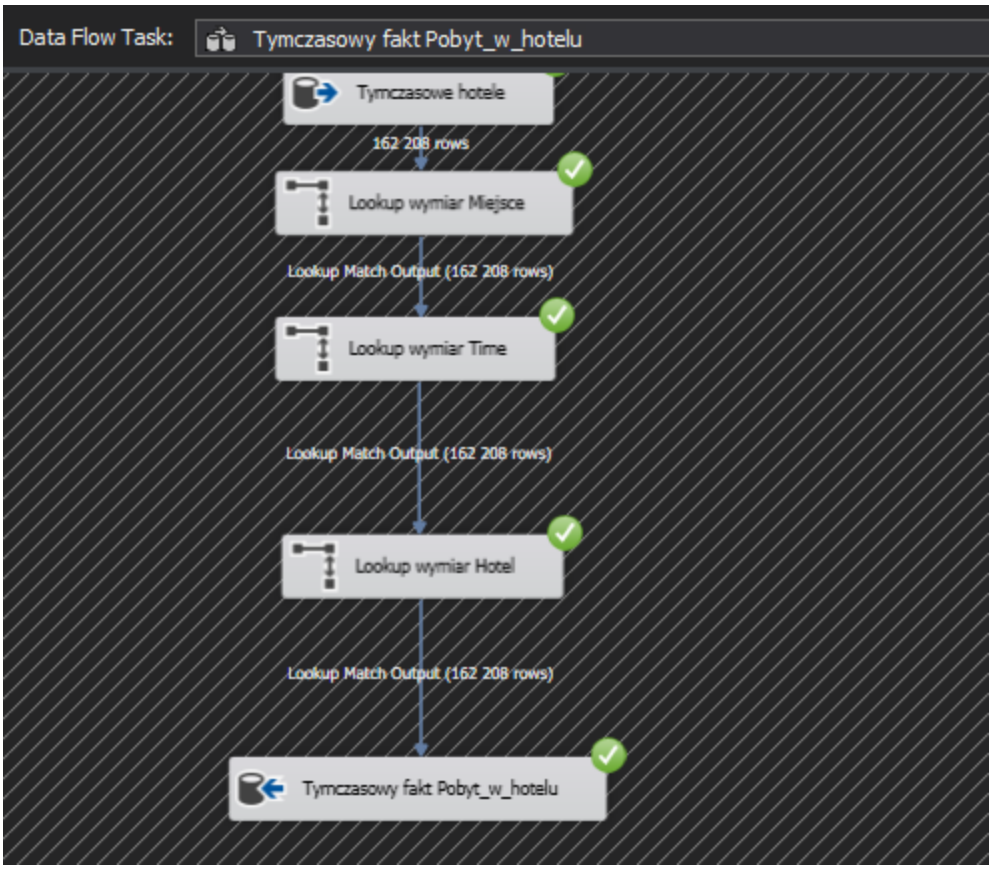

Rysunek 9. Data Flow dla tymczasowego faktu Pobyt_w_hotelu

Analogicznie tworzy się Data Flow dla tymczasowego faktu Przelot oraz dla faktu Przelot i faktu Pobyt_w_hotelu.

6. Implementacja modeli wielowymiarowych

6.1. Widok danych

Utworzony Data Source View został przedstawiony na rysunku 10.

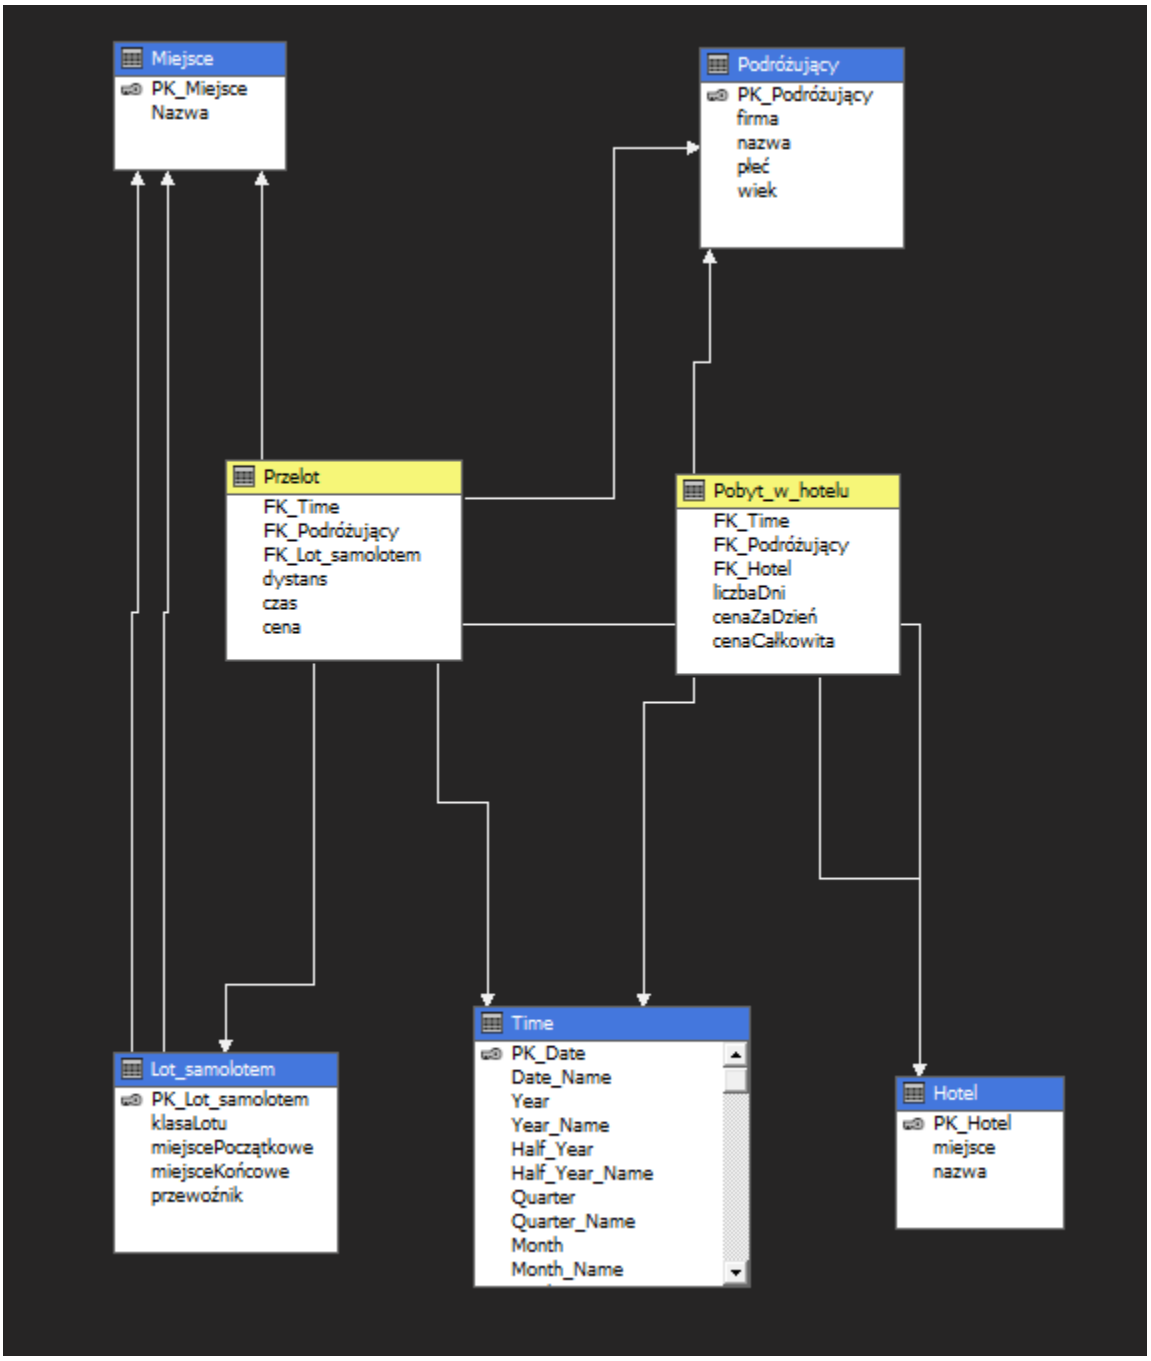

Rysunek 10. Data Source View

6.2. Wymiary

Wymiar Time został przedstawiony na rysunku 11.

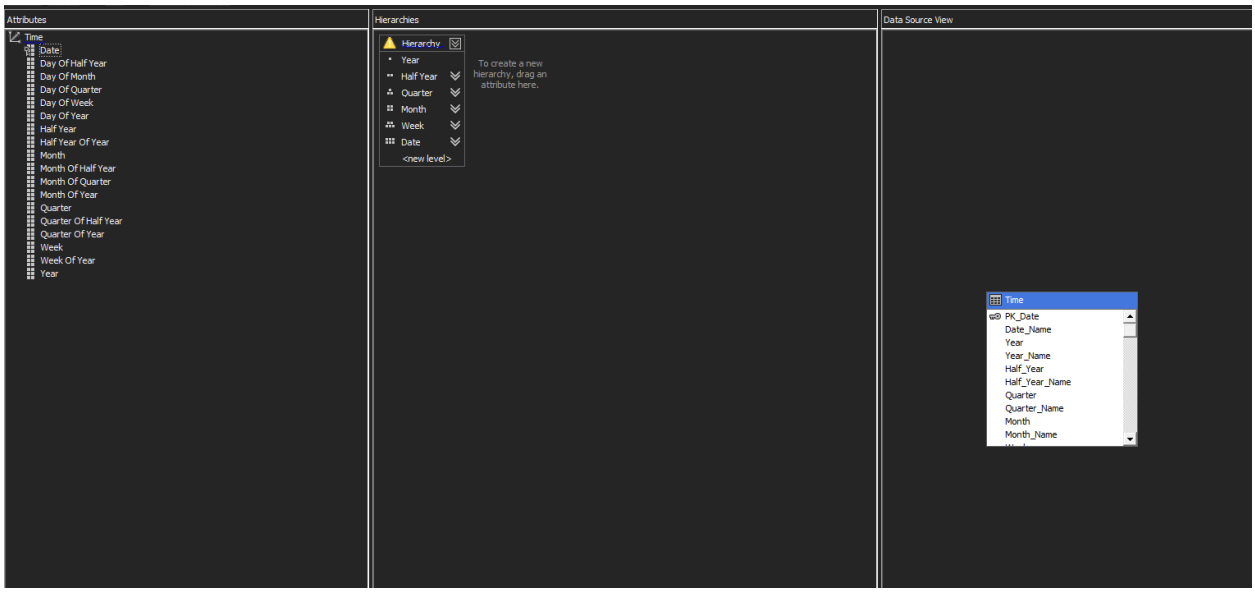

Rysunek 11. Wymiar Time

Wymiar Podróżujący został przedstawiony na rysunku 12.

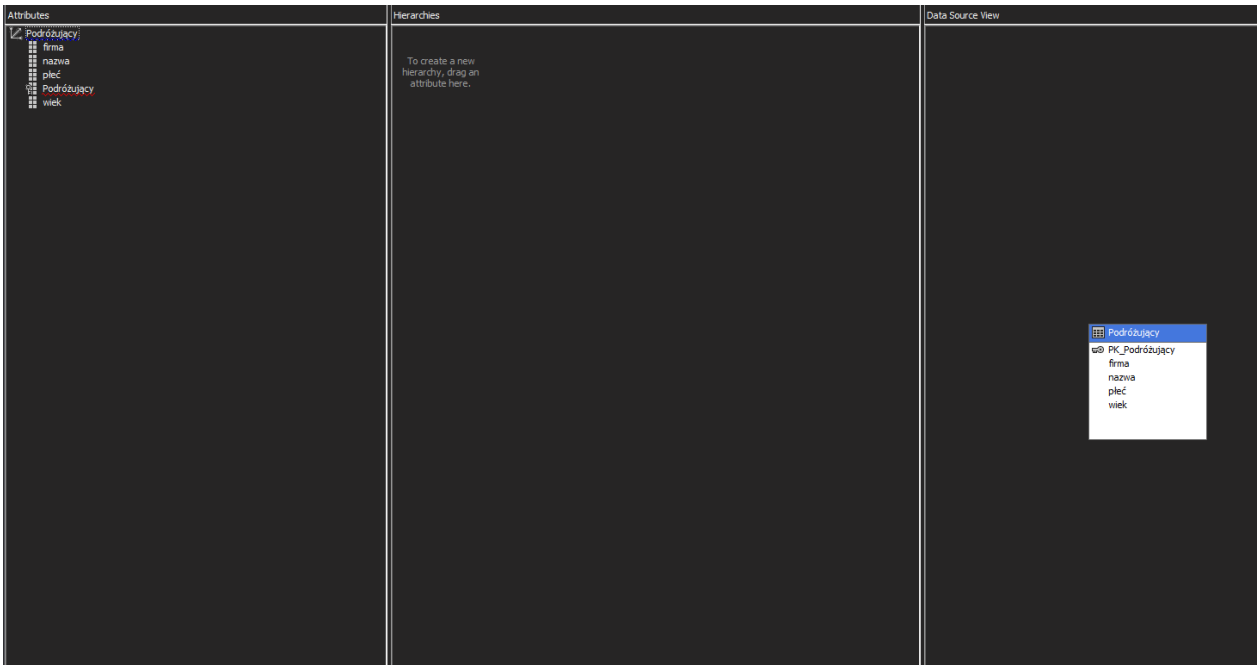

Rysunek 12. Wymiar Podróżujący

Wymiar Lot_samolotem został przedstawiony na rysunku 13.

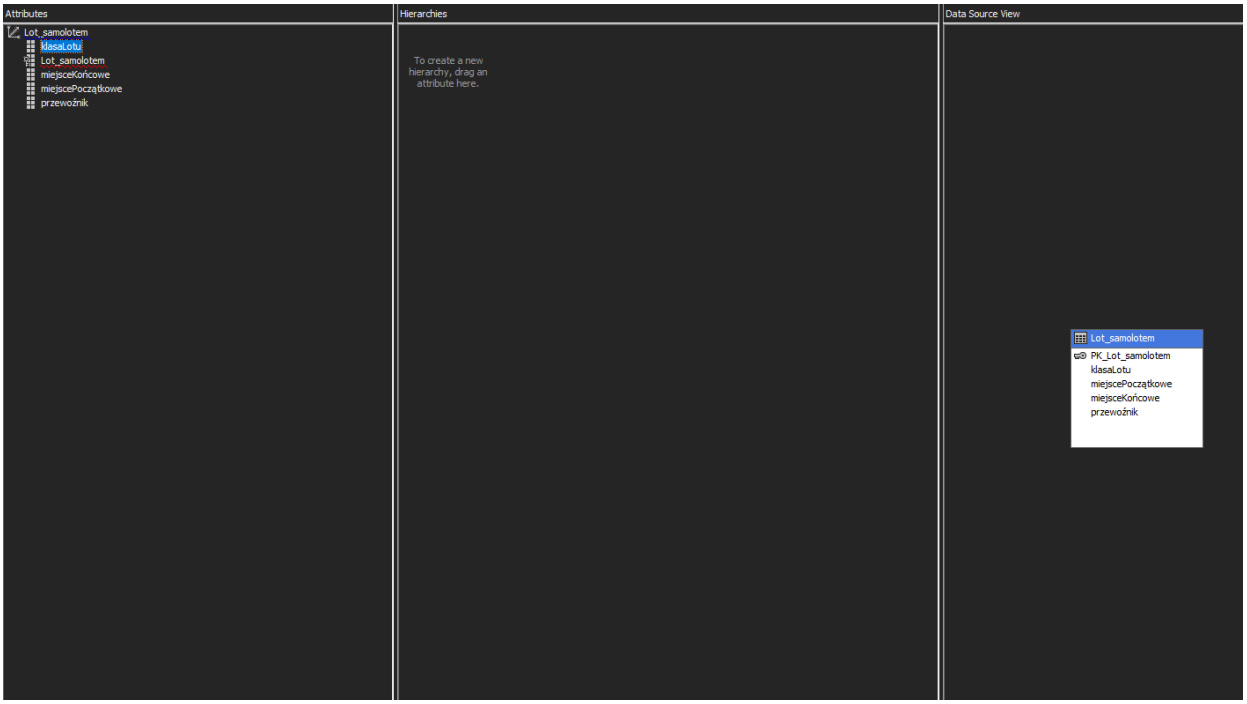

Rysunek 13. Wymiar Lot samolotem

Wymiar Hotel został przedstawiony na rysunku 14.

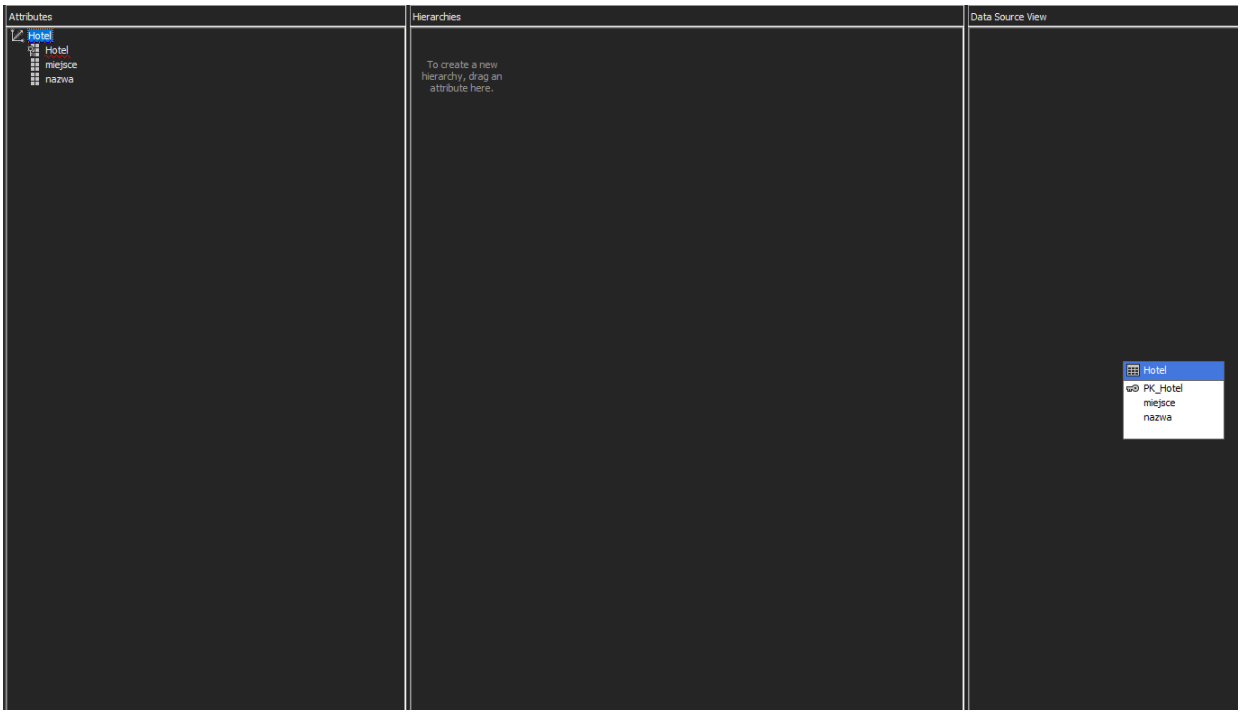

Rysunek 14. Wymiar Hotel

Wymiar Miejsce został przedstawiony na rysunku 15.

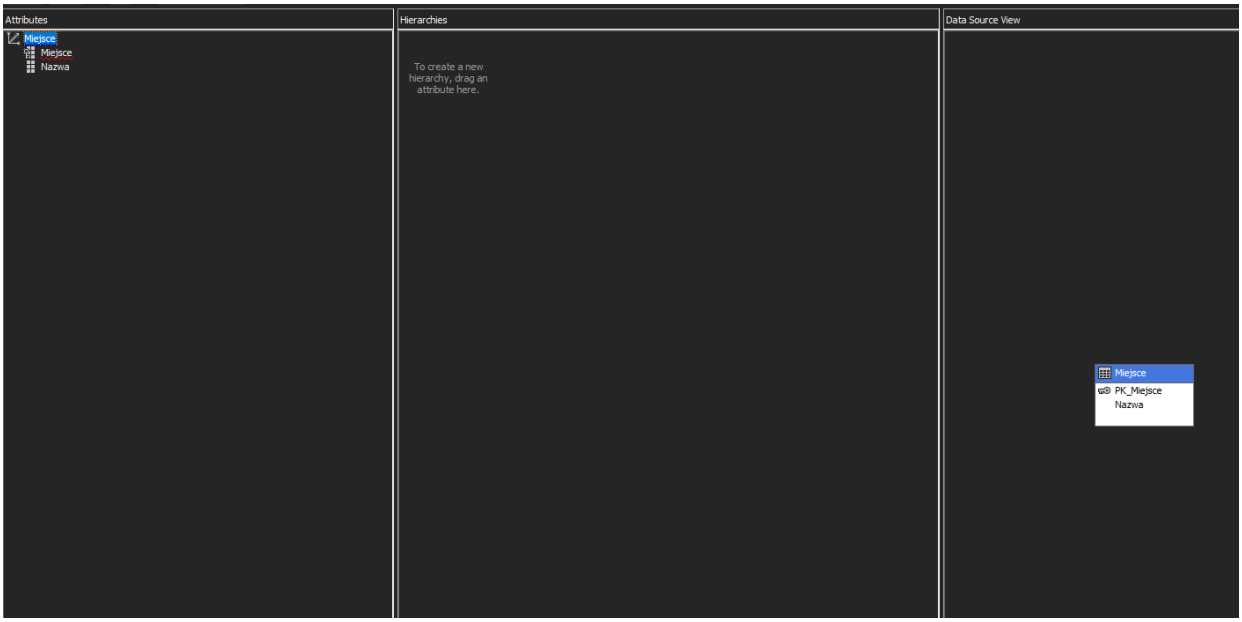

Rysunek 15. Wymiar Miejsce

6.3. Modele wielowymiarowe – Kostki

Utworzona kostka została przedstawiona na rysunku 16.

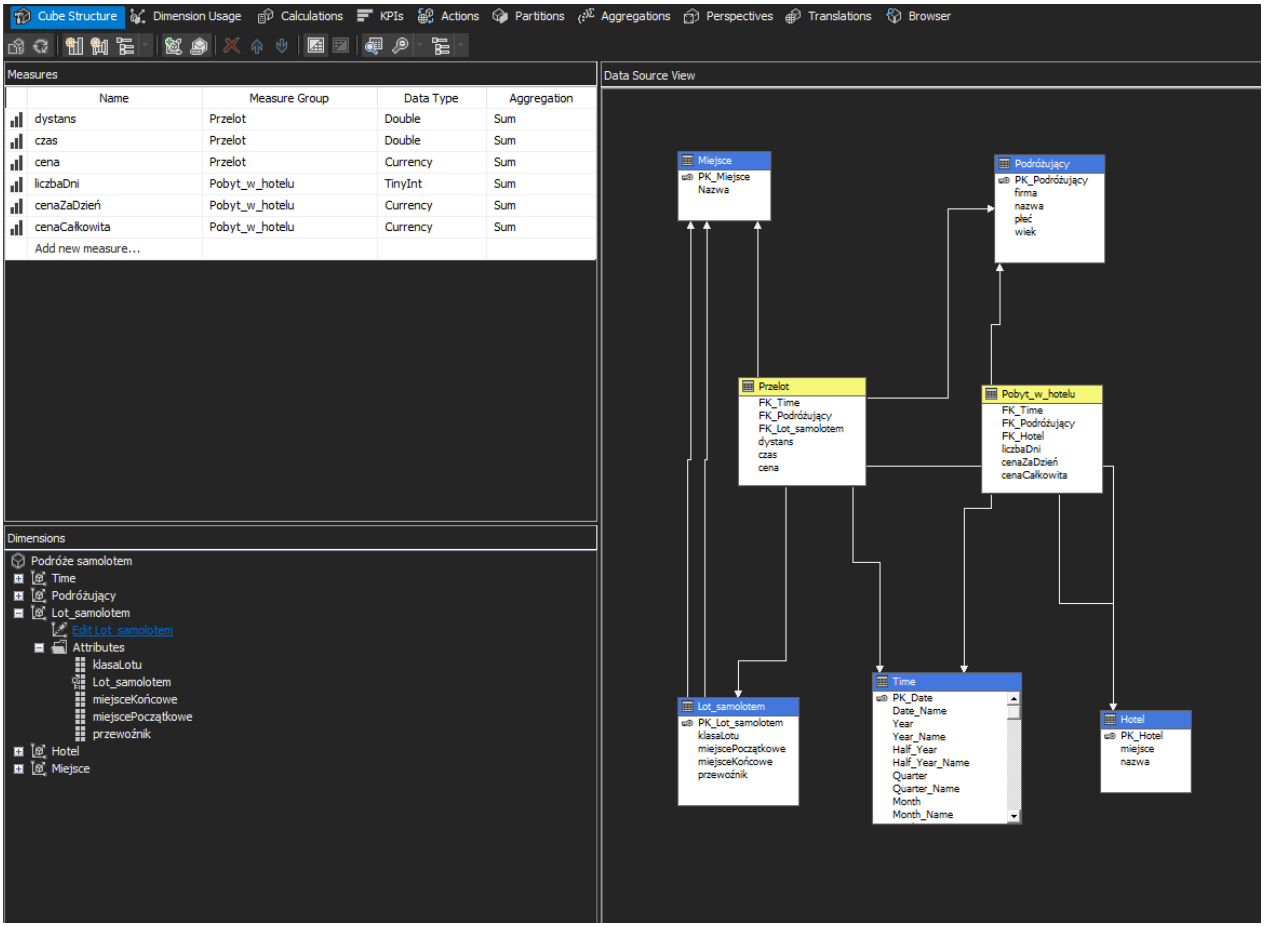

Rysunek 16. Kostka

7. Analiza danych

7.1. Realizacja procesów analitycznych

Jakim przewoźnikiem odbywają się podróże?

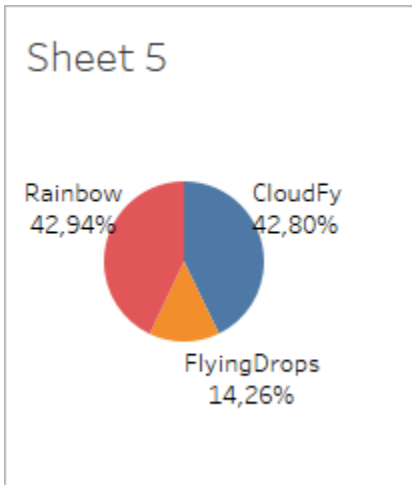

Rysunek 17. Liczba podróży w zależności od przewoźnika

Jak widać na rys. 17 najwięcej podróży odbywa się przewoźnikiem Rainbow oraz Cloudy (na pierwszym miejscu z minimalną przewagą jest Rainbow), a najmniej FlyingDrops. Jest tylko trzech przewoźników. Różnica między liczbą podróży Rainbowem a FlyingDrops jest bardzo duża (3-krotnie więcej Rainbowem).

Dokąd odbywają się podróże?

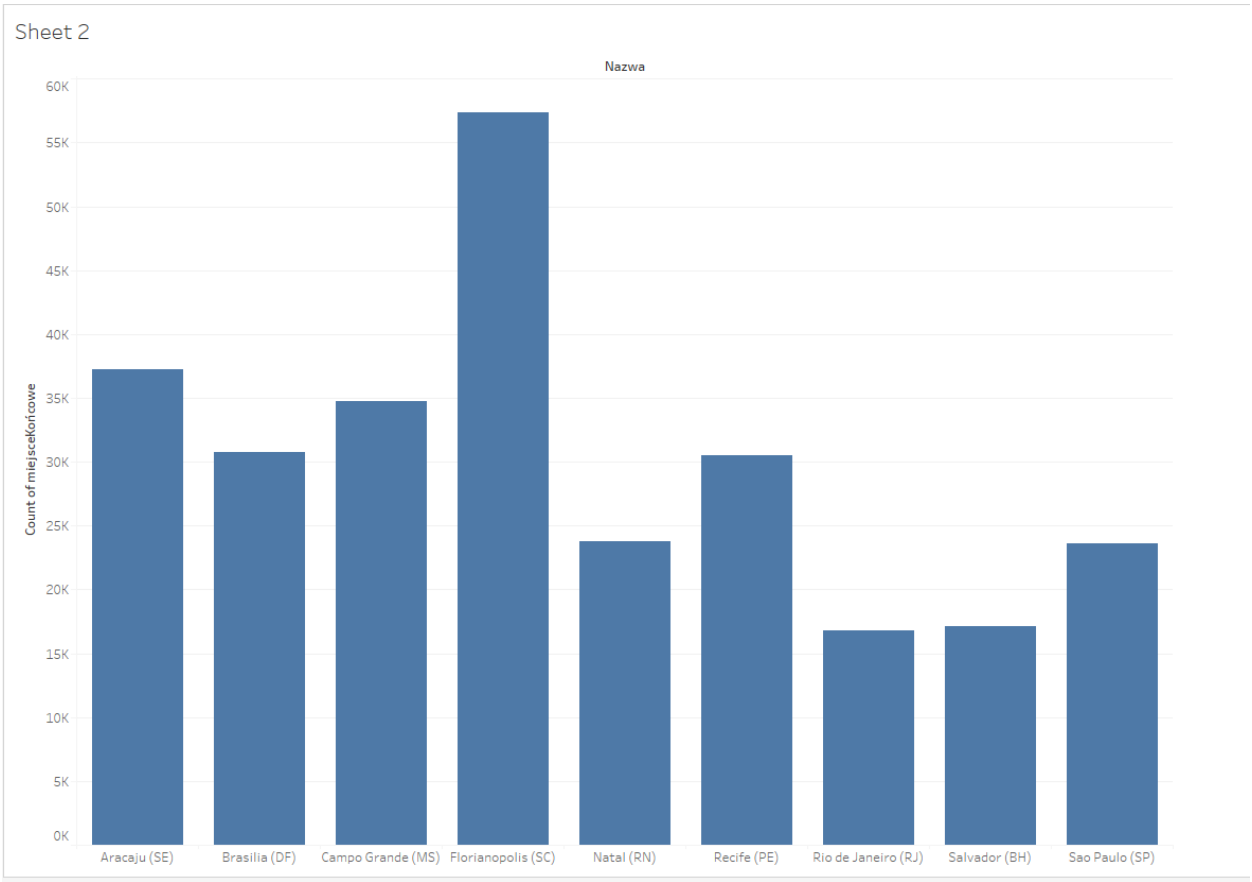

Rysunek 18. Liczba podróży w zależności od nazwy miasta końcowego

Jak widać na rys. 18 najwięcej podróży odbywa się do miasta Florianopolis. Na kolejnych miejscach są miasta Aracaju, Campo Grande, Brasilia. Najmniej podróży kończy się w mieście Rio de Janeiro oraz Salvador. Florianopolis wyraźnie przoduje nad pozostałymi miejscami.

Jaka jest klasa miejsca lotu?

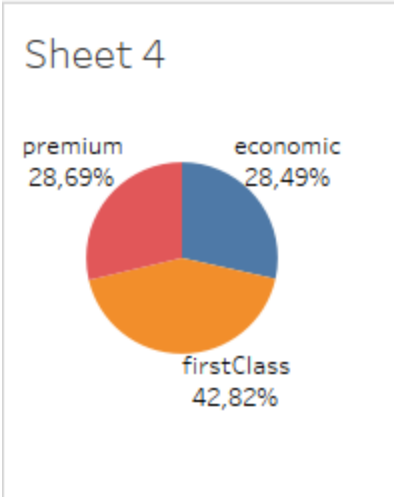

Rysunek 19. Procentowy rozkład klasy lotu

Z rys. 19. można odczytać że podróżujący najczęściej wybierają pierwszą klasę miejsca. Jeśli chodzi o wybór pozostałych klas, to częstotliwość wyboru jest dosyć podobna (najrzadziej wybierana klasa to klasa ekonomiczna).

Kiedy najczęściej odbywają się podróże?

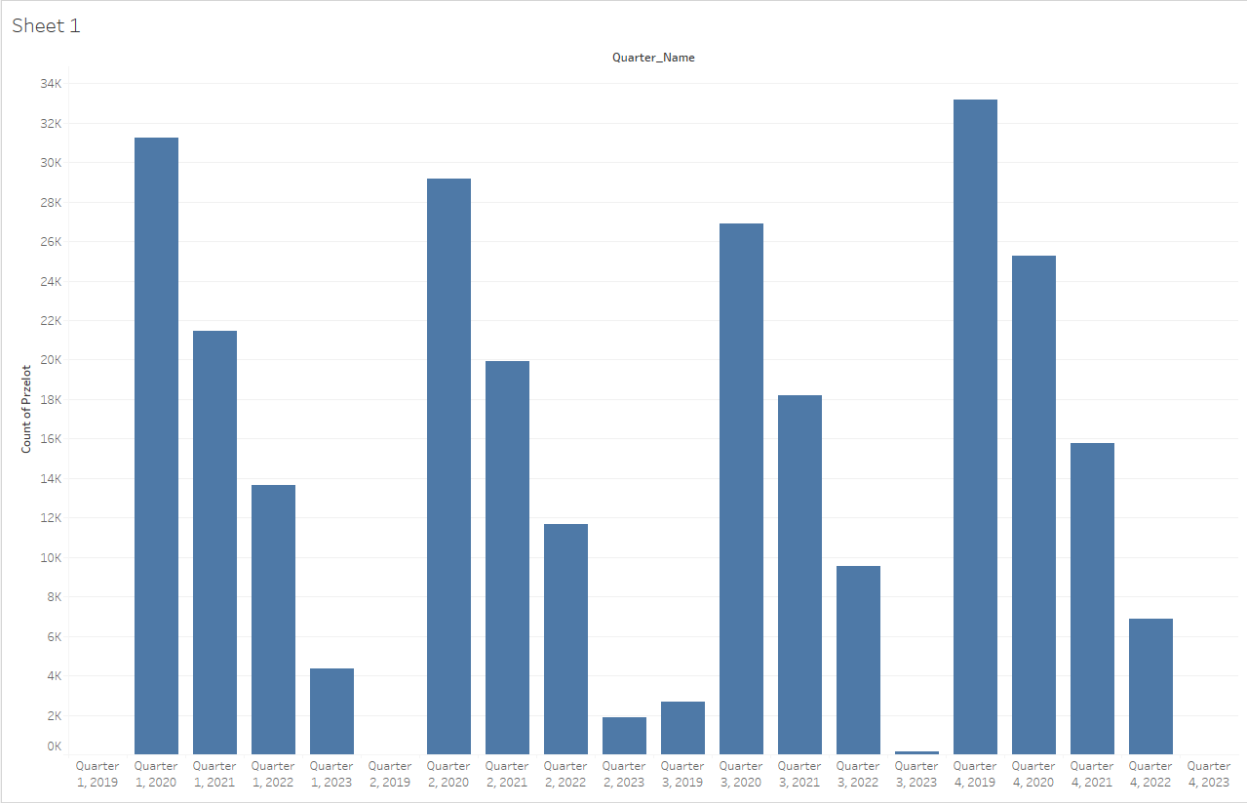

Rysunek 20. Liczba podróży w zależności od kwartału w poszczególnych latach

Z rys. 20. można odczytać, że najwięcej lotów ma miejsce w pierwszym kwartale (brazylijskie lato – źródło 1). Szczególnie dobrze jest to widoczne na poniższych wykresach: rys. 21, rys. 22 oraz rys. 23. W roku 2019 reguła ta nie jest spełniona, ale to ze względu na brak danych z pierwszych miesięcy.

Oprócz tego można zauważyć, że w roku 2020 miało miejsce najwięcej podróży, co najlepiej obrazuje rys. 24.

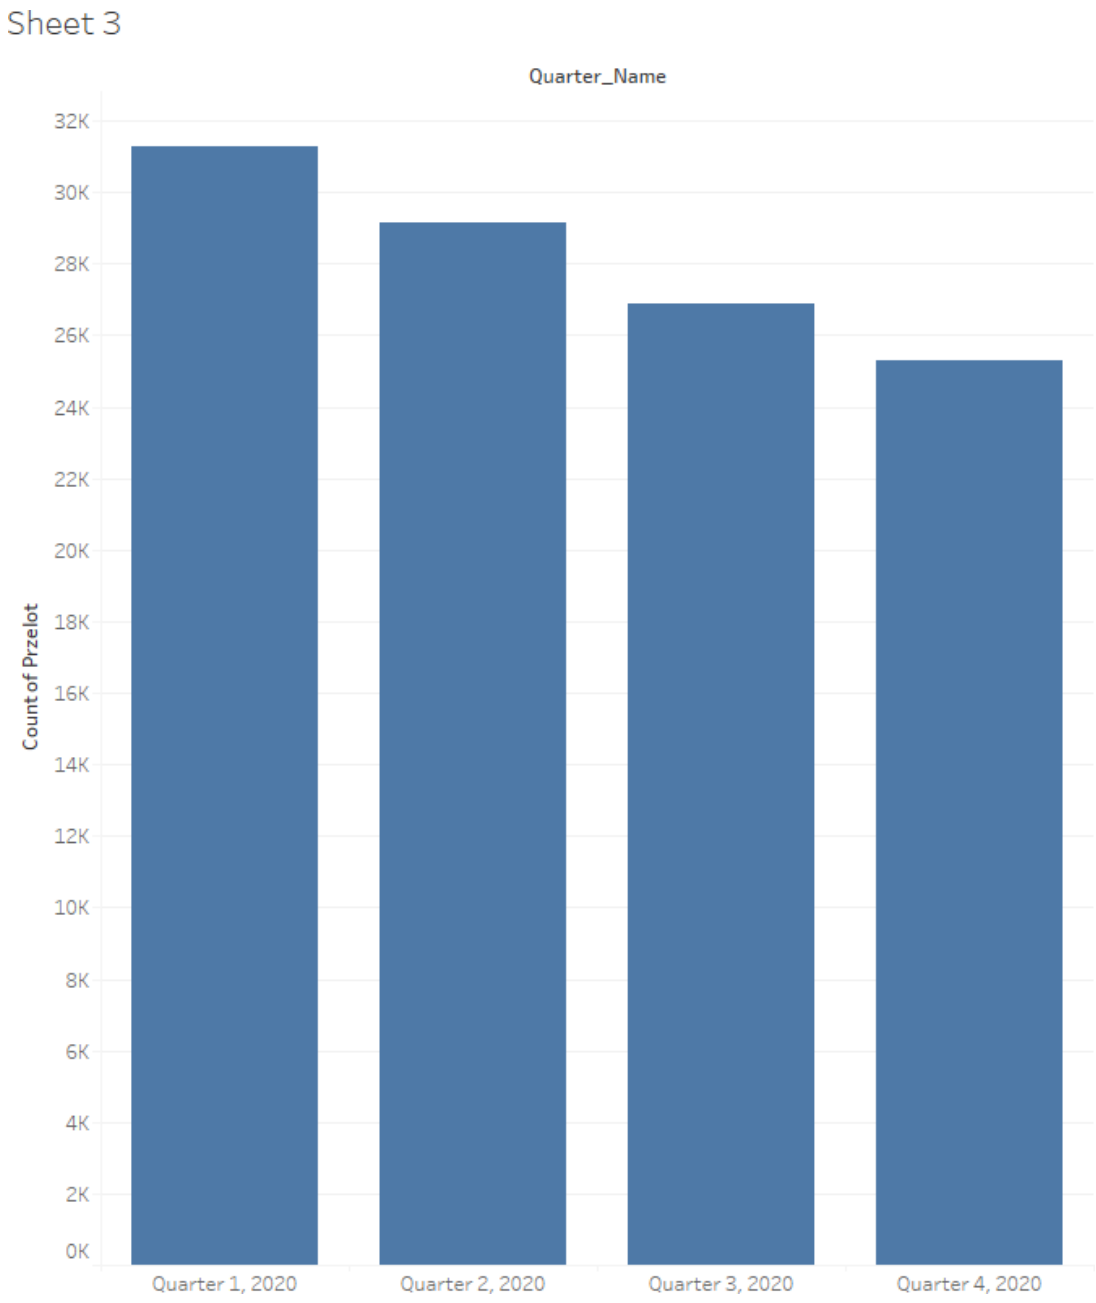

Rysunek 21. Liczba podróży w zależności od kwartału w 2020 roku

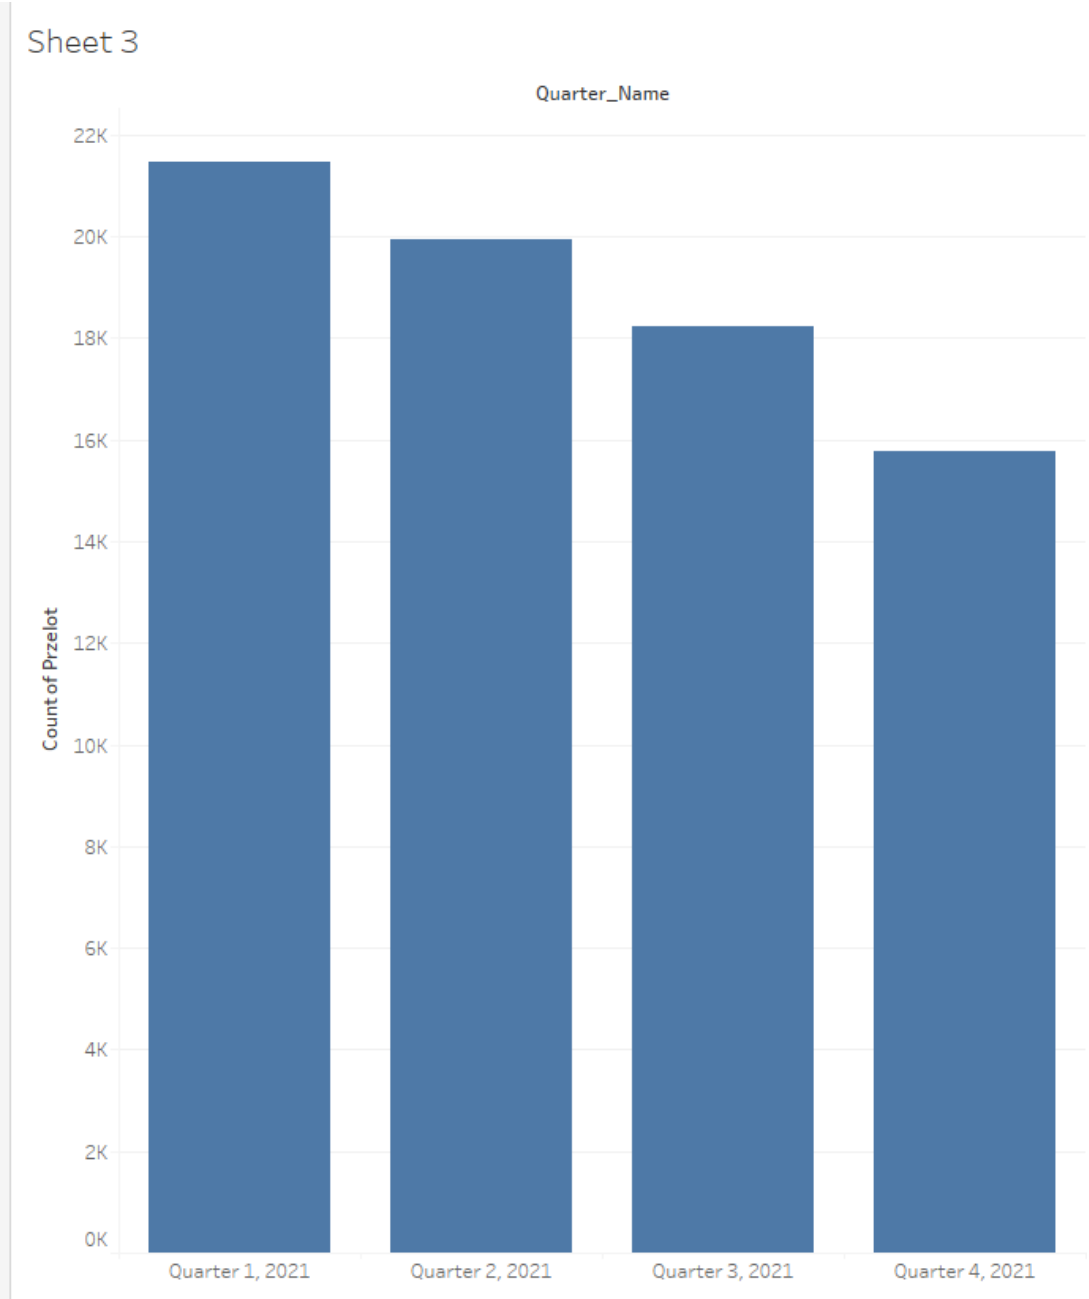

Rysunek 22. Liczba podróży w zależności od kwartału w 2021 roku

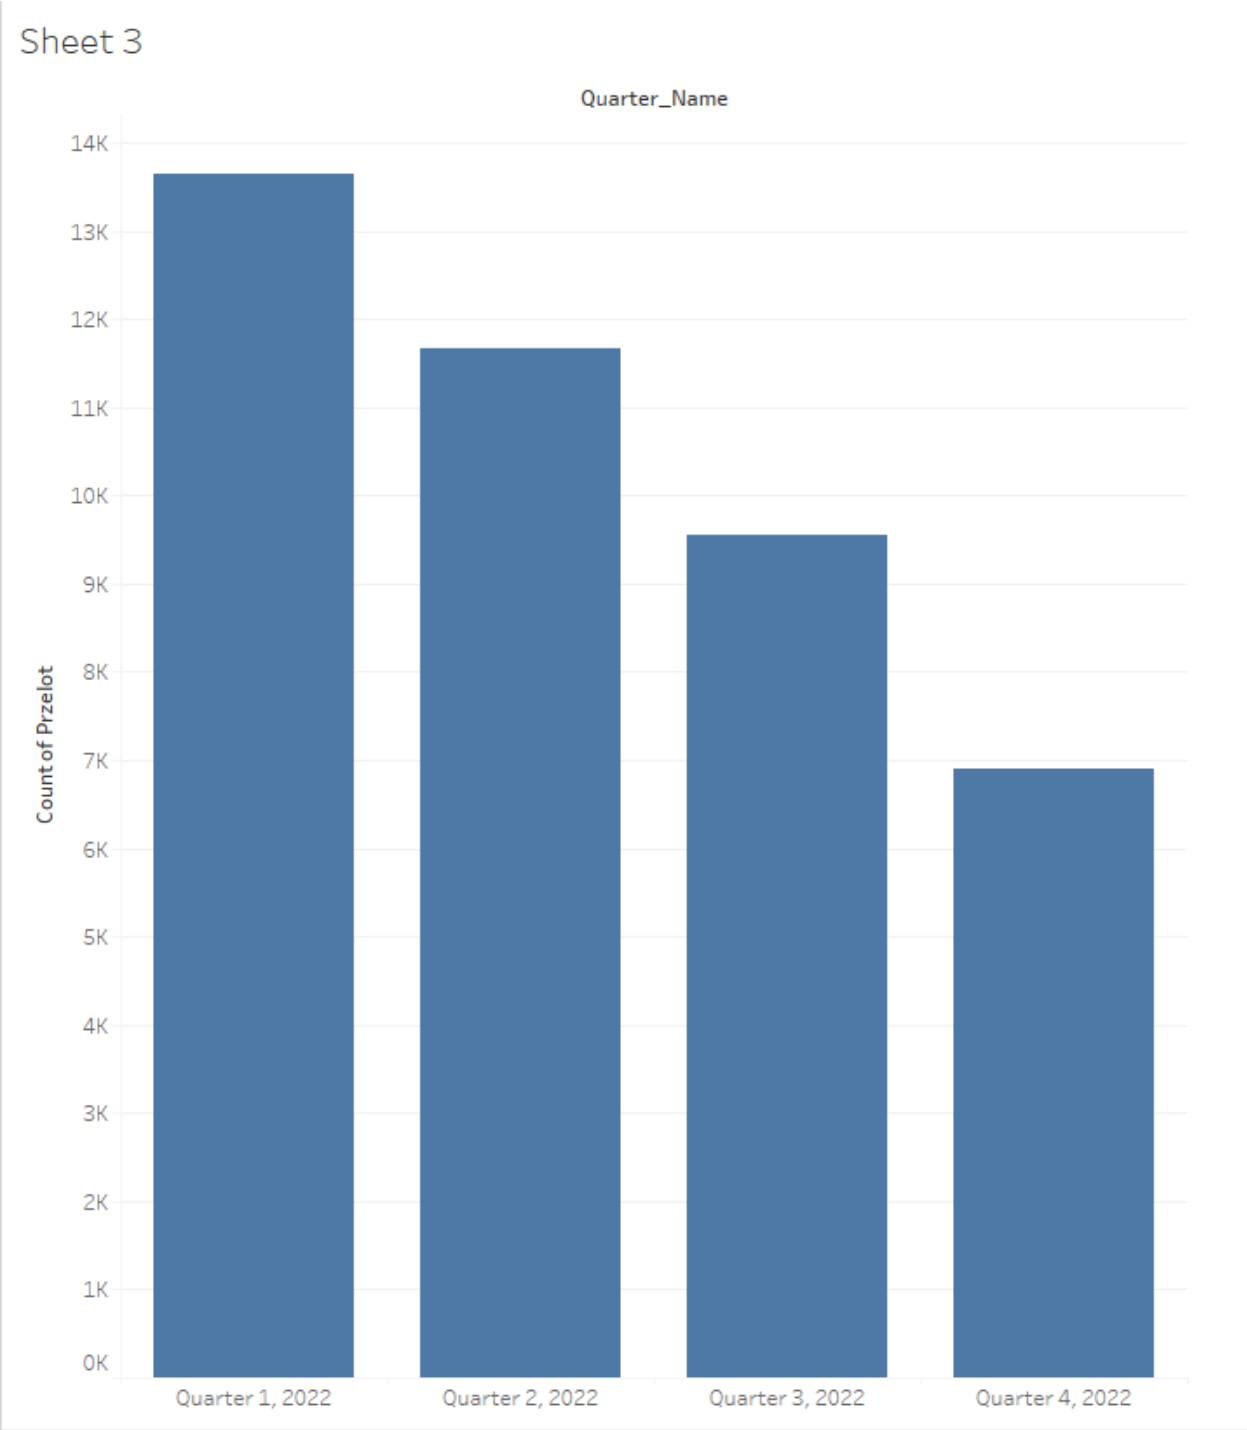

Rysunek 23. Liczba podróży w zależności od kwartału w 2022 roku

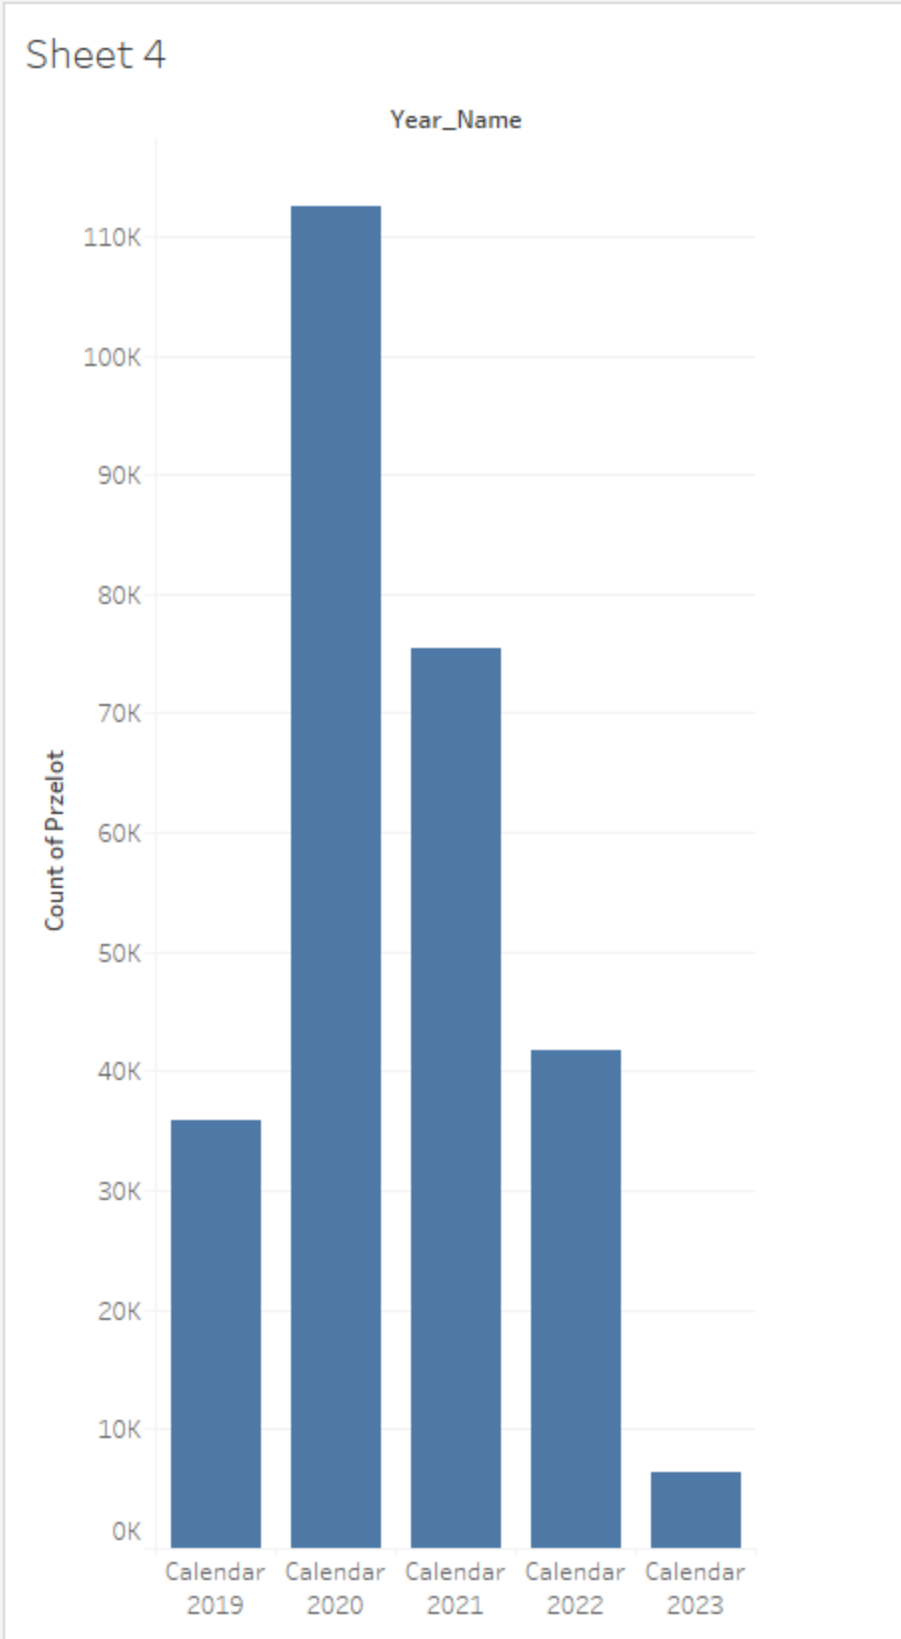

Rysunek 24. Liczba podróży w zależności od roku

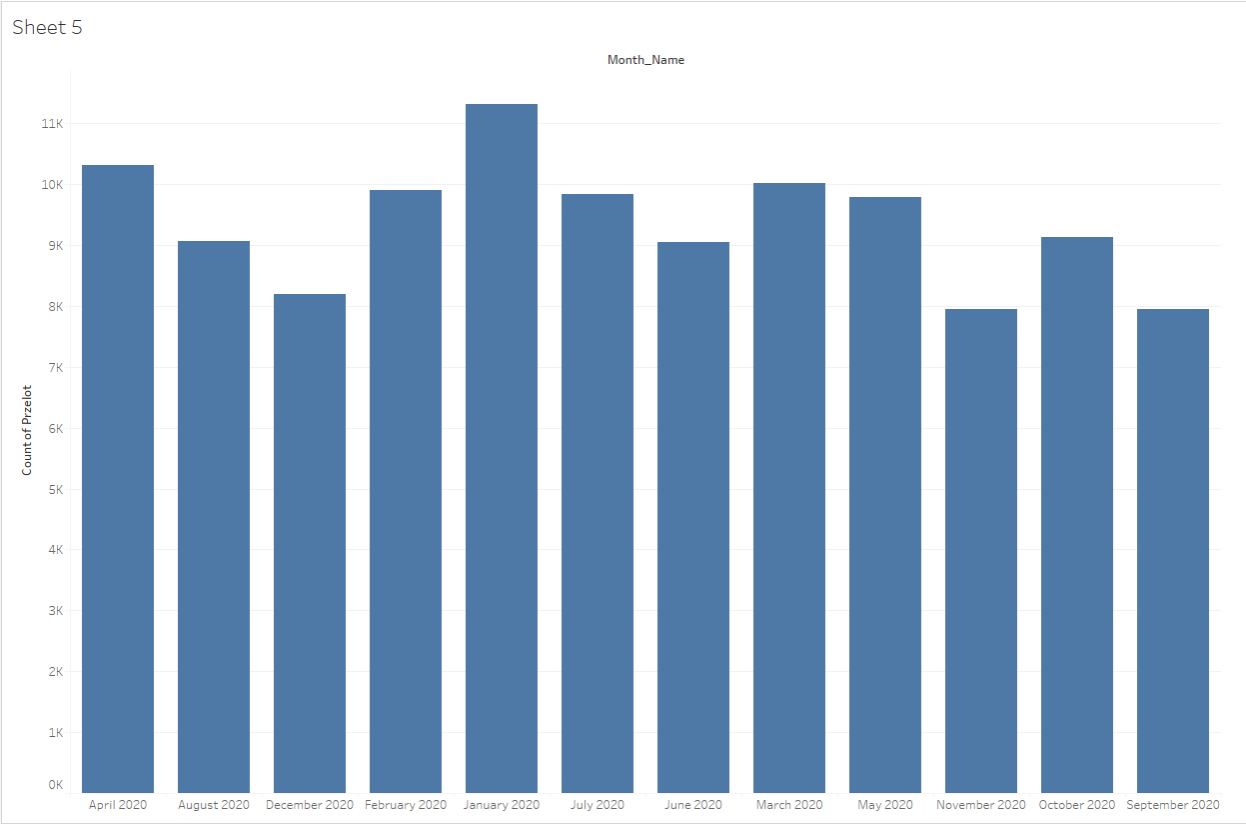

Rysunek 25. Liczba podróży w 2020 roku w zależności od miesiąca

Jak widać na rys. 25. najwięcej podróży miało miejsce w styczniu, wysoko jest też luty i marzec co potwierdza fakt, iż najwięcej podróży miało miejsce w miesiącach letnich w Brazylii. Podobna sytuacja ma miejsce na rys. 26 i rys. 27, które przedstawiają dane z kolejnych lat. Najmniej podróży miało miejsce w listopadzie, grudniu i wrześniu. Podobna sytuacja jest na wykresie rys. 26 i rys. 27 (listopad i grudzień najmniej).

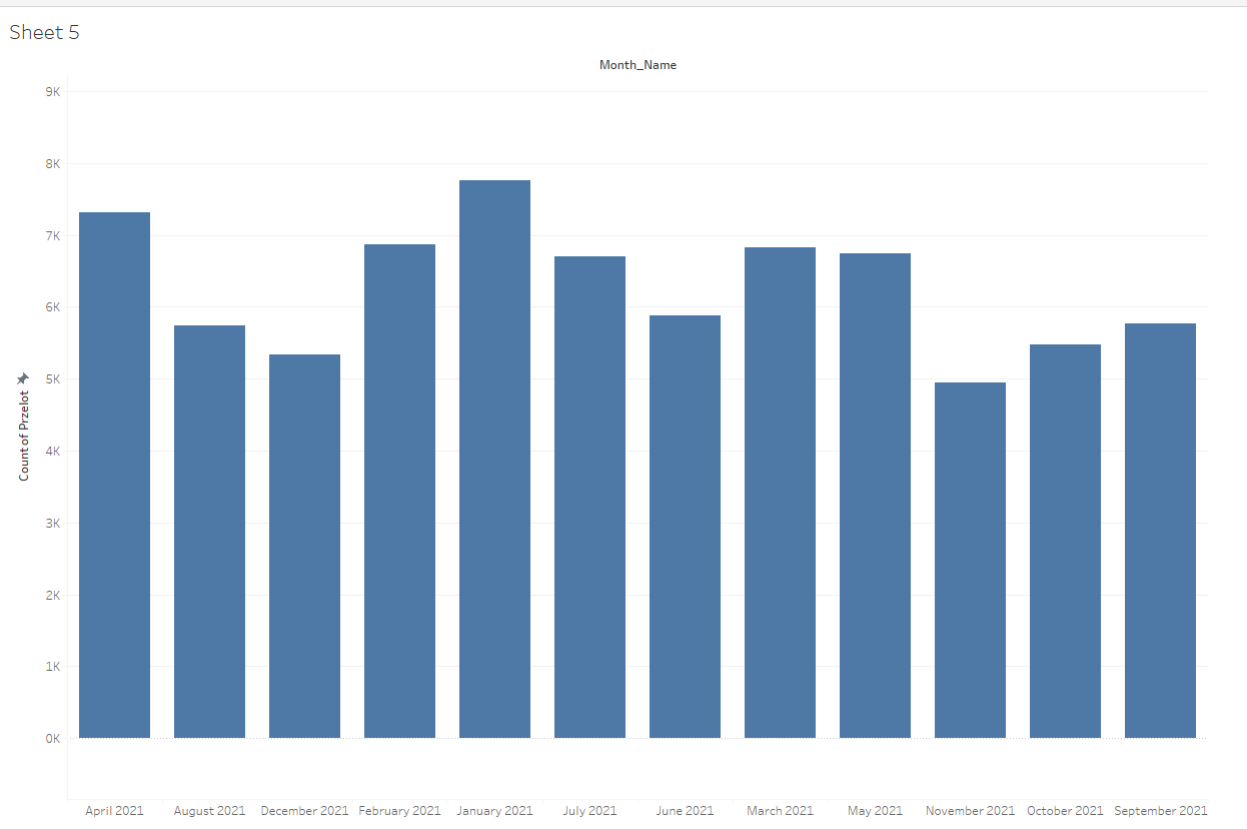

Rysunek 26. Liczba podróży w 2021 roku w zależności od miesiąca

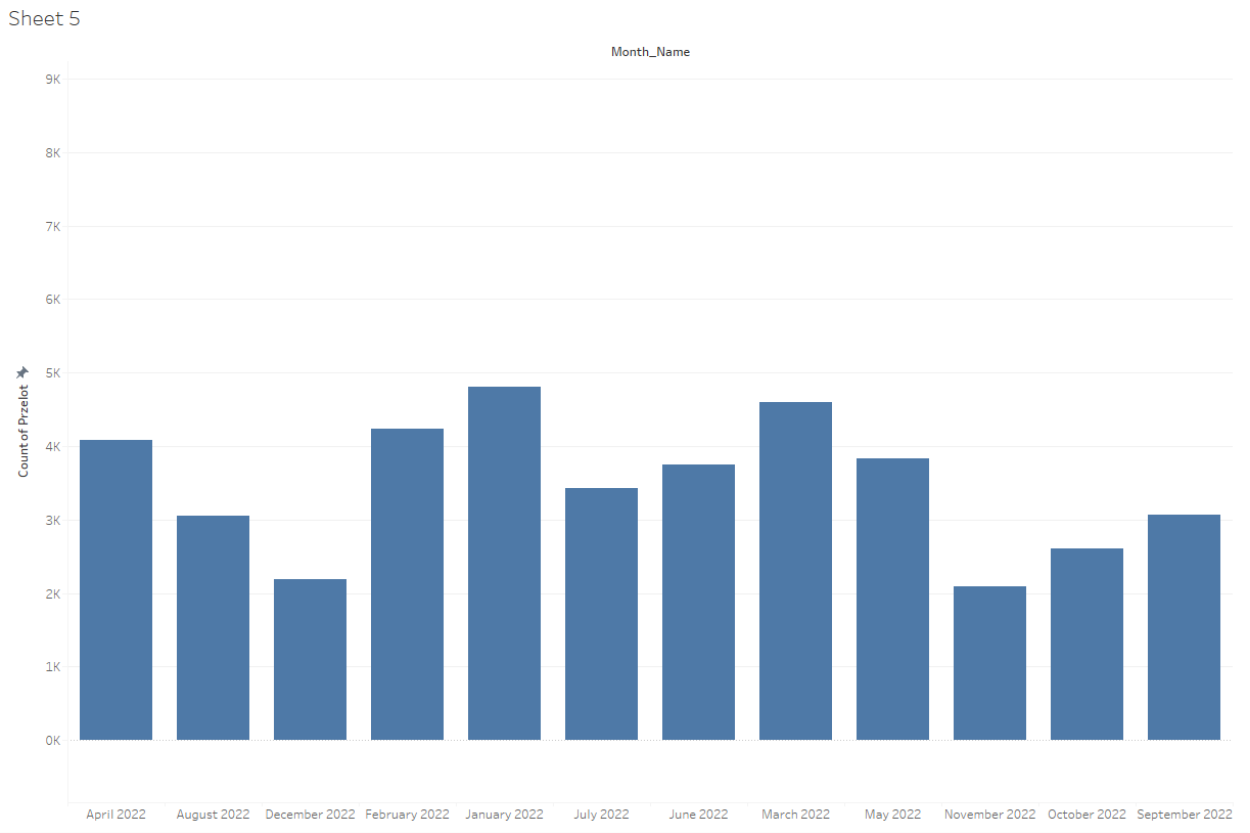

Rysunek 27. Liczba podróży w 2022 roku w zależności od miesiąca

W jakich hotelach najczęściej odpoczywają podróżujący?

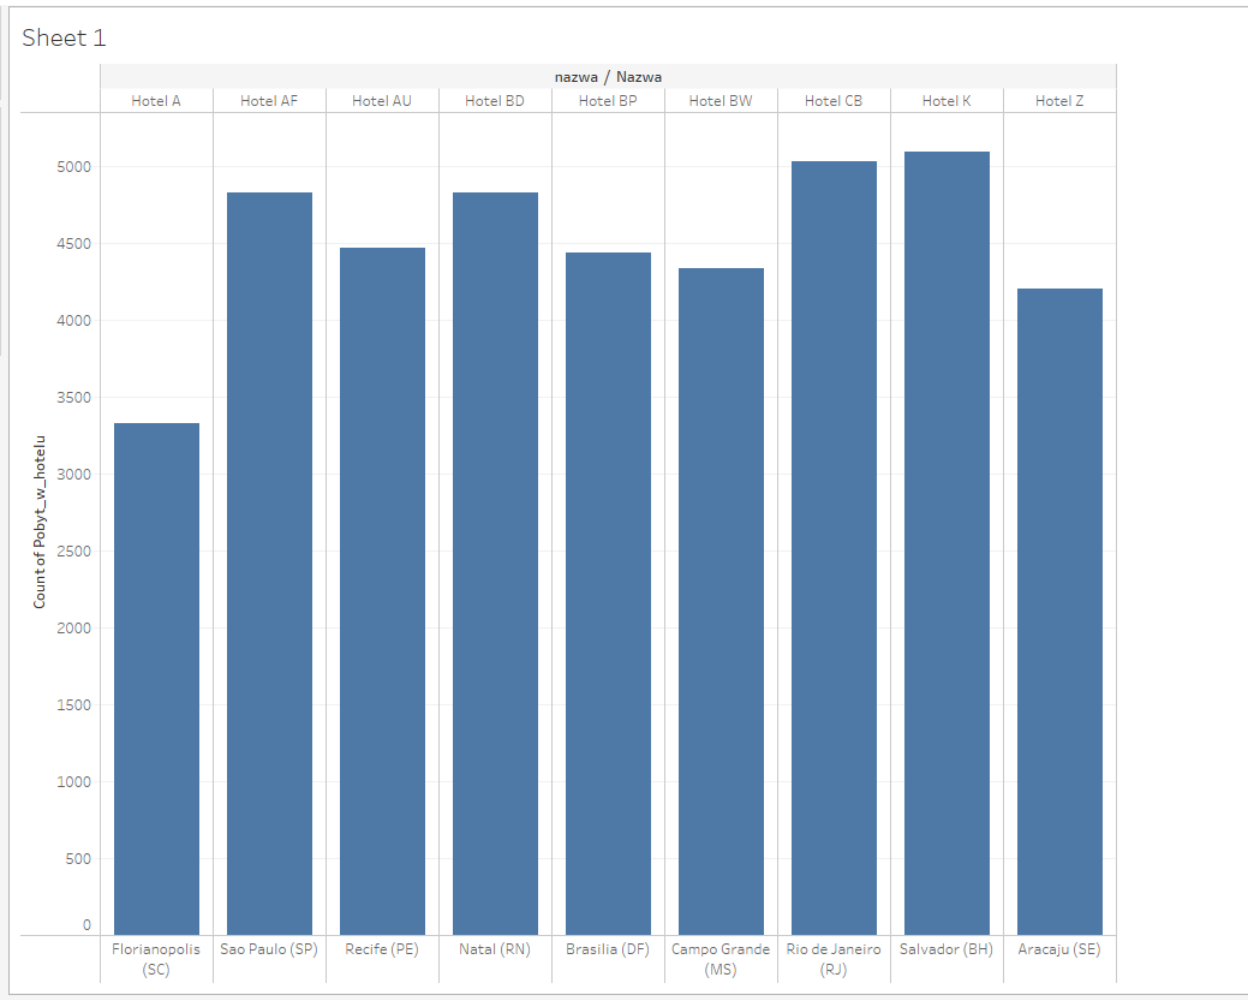

Rysunek 28. Liczba pobytów w hotelu w zależności od nazwy hotelu/nazwy miasta

Jak widać na rysunku 28. najwięcej do obsłużenia gości mieli w hotelu K oraz CB mieszących się w miastach odpowiednio Salvador oraz Rio de Janeiro, a najmniej w hotelu A znajdującym się w Florianopolis.

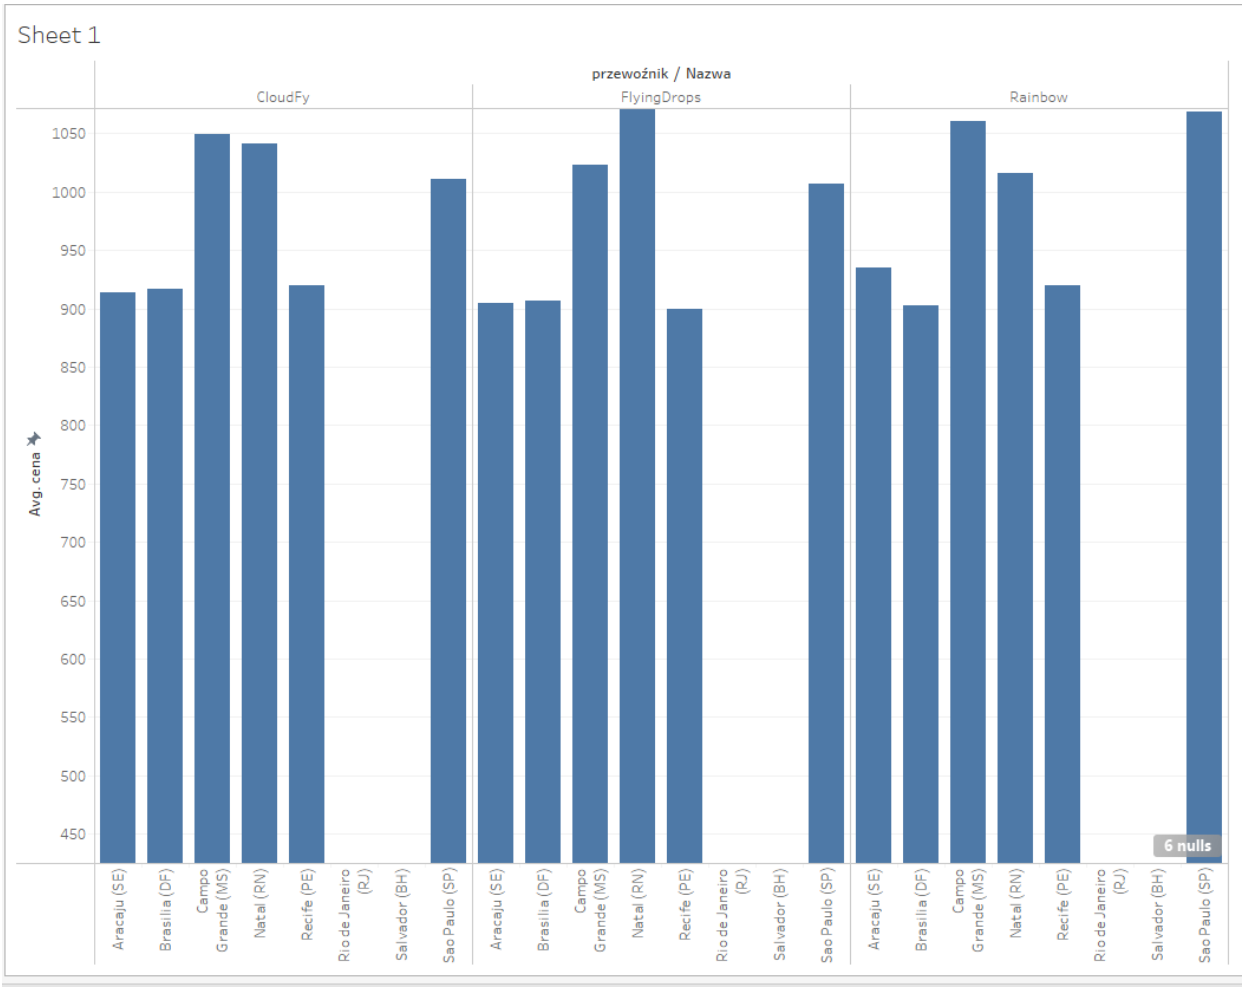

Rysunek 29. Średnia cena lotu z Florianopolis w zależności od nazwy przewoźnika oraz miejsca docelowego

Jak widać na rys. 29, 30, 31, 32, 33, 34, 35, 36, 37 ceny u różnych przewoźników na tych samych liniach są różne.

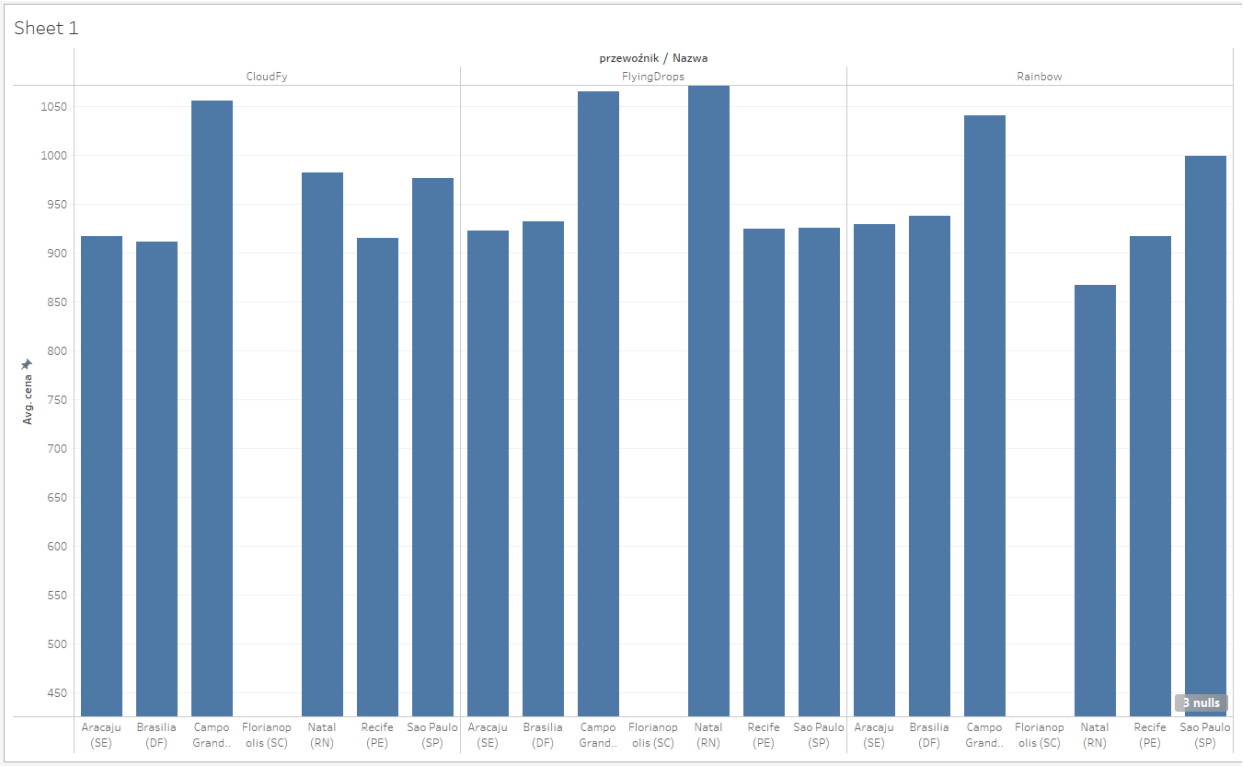

Rysunek 30. Średnia cena lotu z Salvador w zależności od nazwy przewoźnika oraz miejsca docelowego

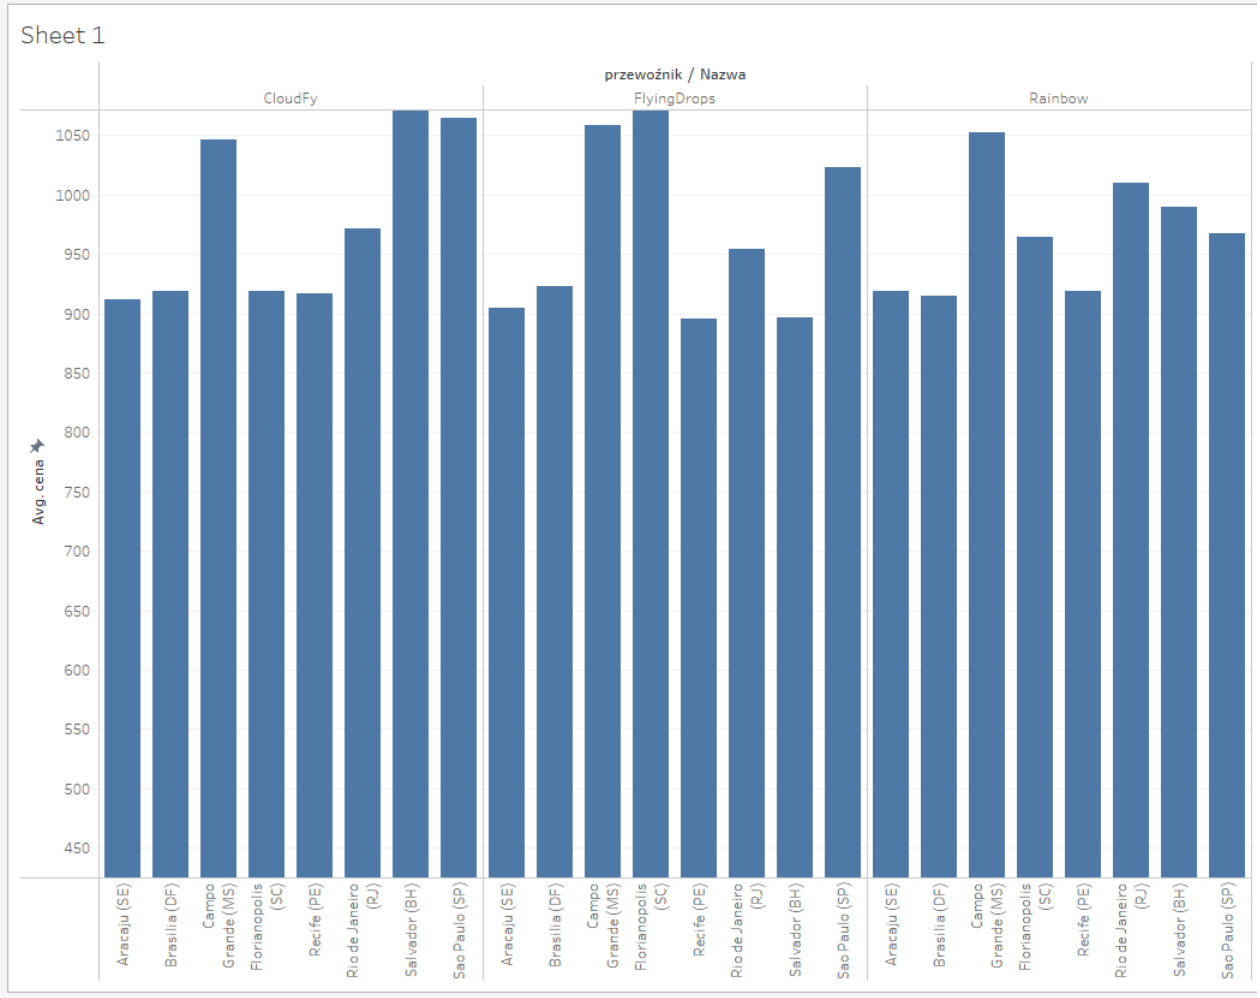

Rysunek 31. Średnia cena lotu z Natal w zależności od nazwy przewoźnika oraz miejsca docelowego

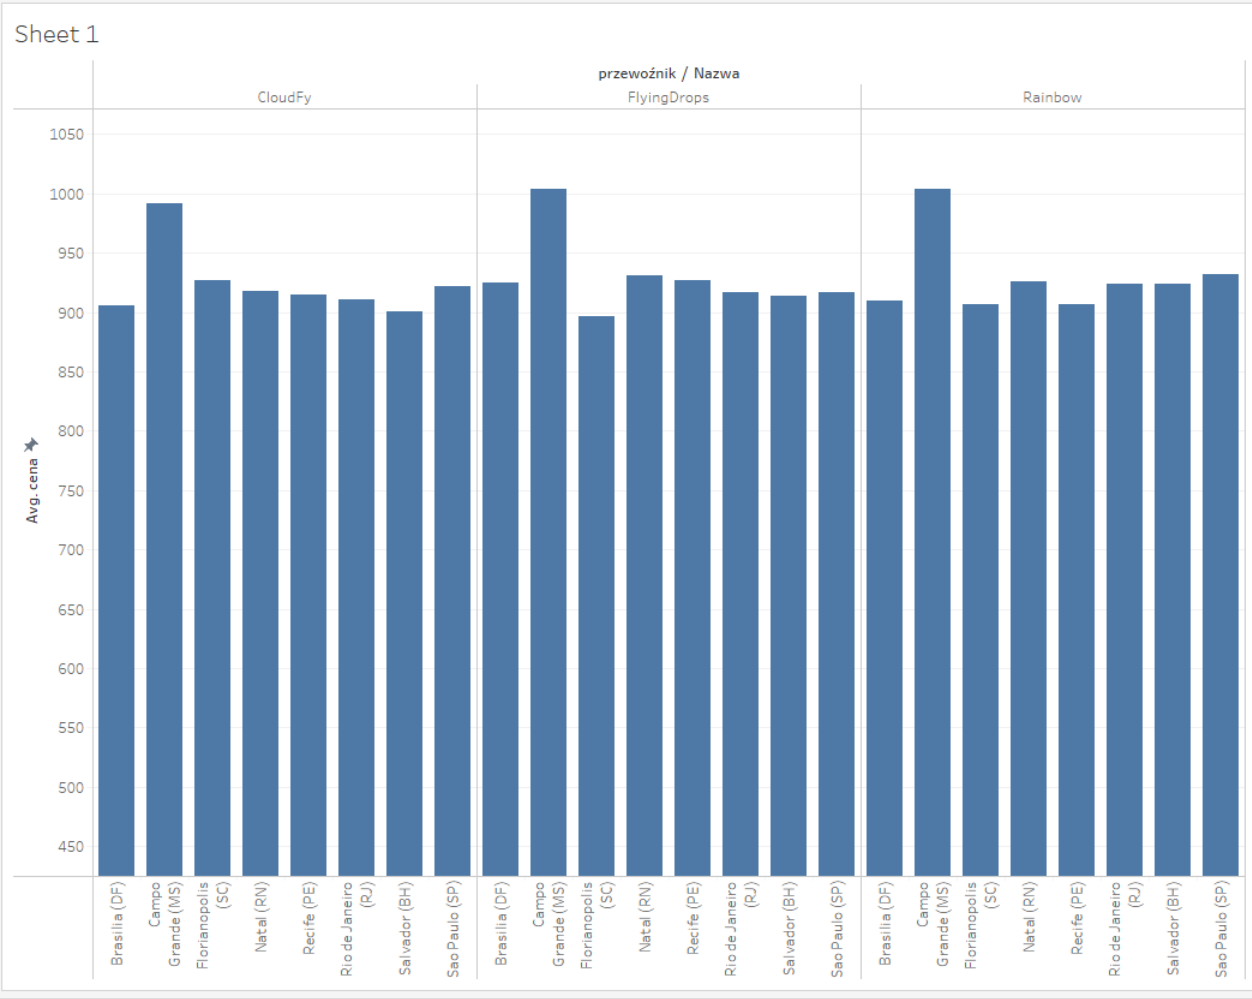

Rysunek 32. Średnia cena lotu z Aracaju w zależności od nazwy przewoźnika oraz miejsca docelowego

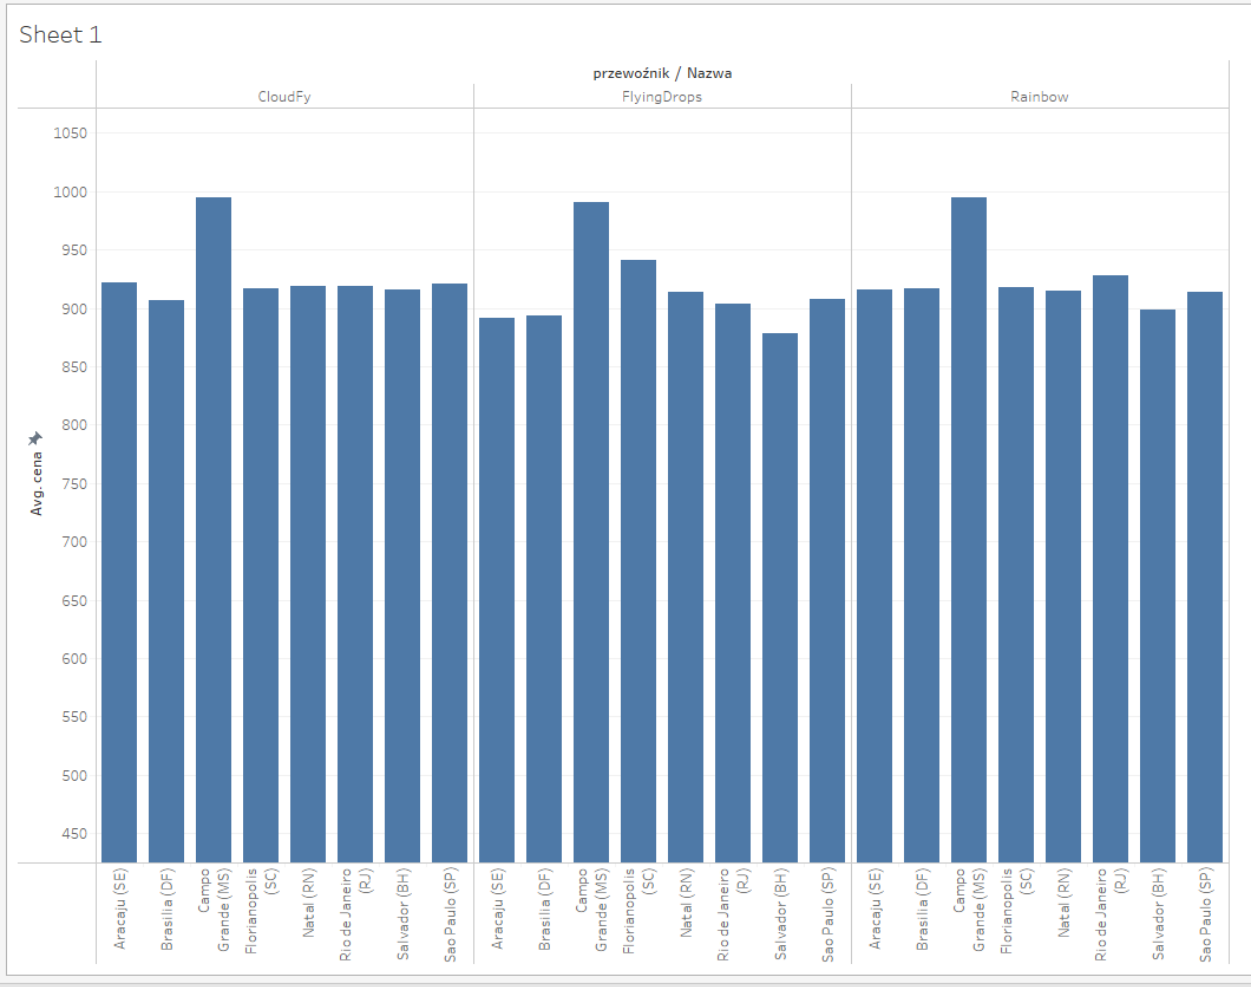

Rysunek 33. Średnia cena lotu z Recife w zależności od nazwy przewoźnika oraz miejsca docelowego

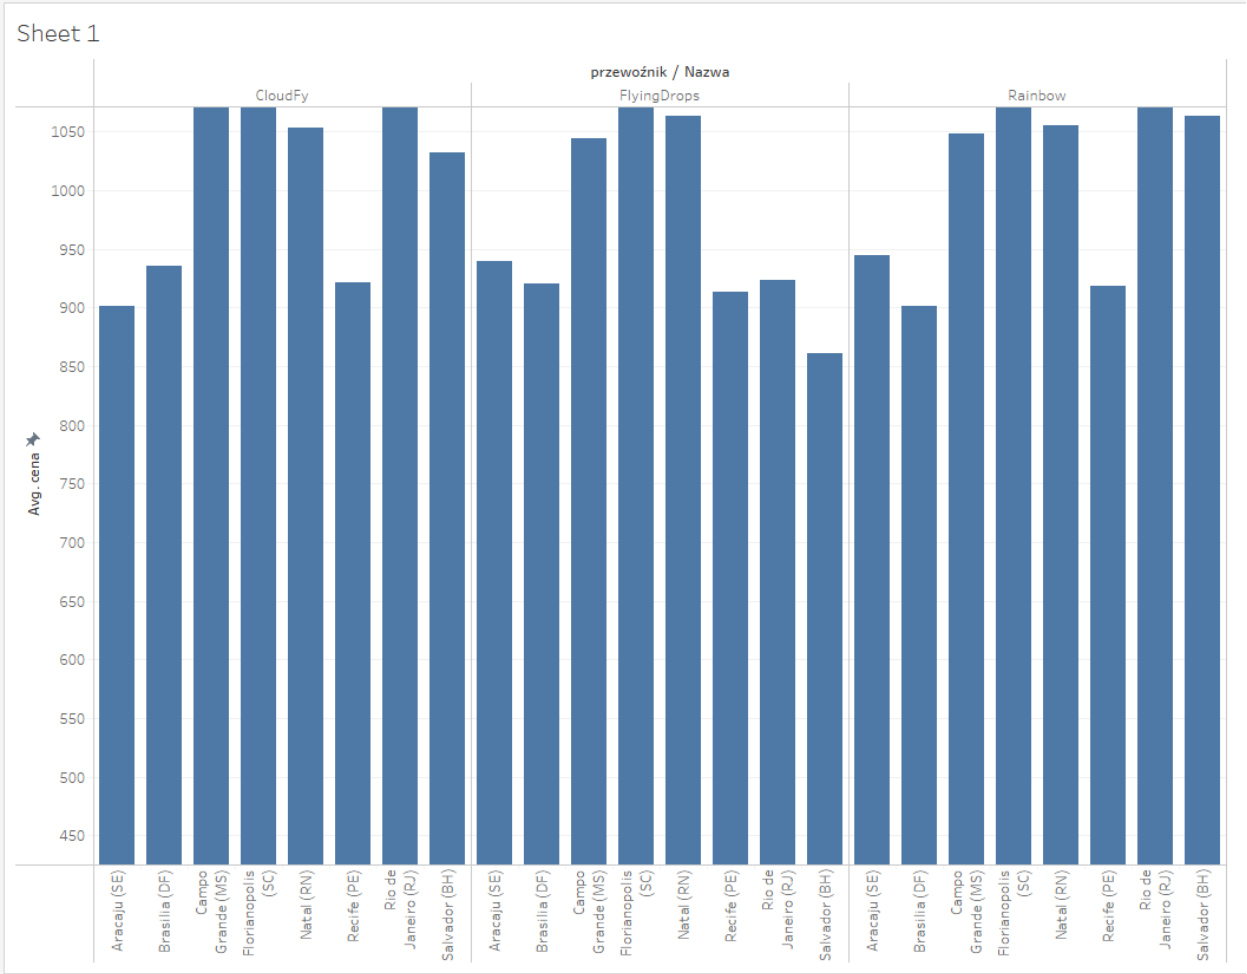

Rysunek 34. Średnia cena lotu z Sao Paulo w zależności od nazwy przewoźnika oraz miejsca docelowego

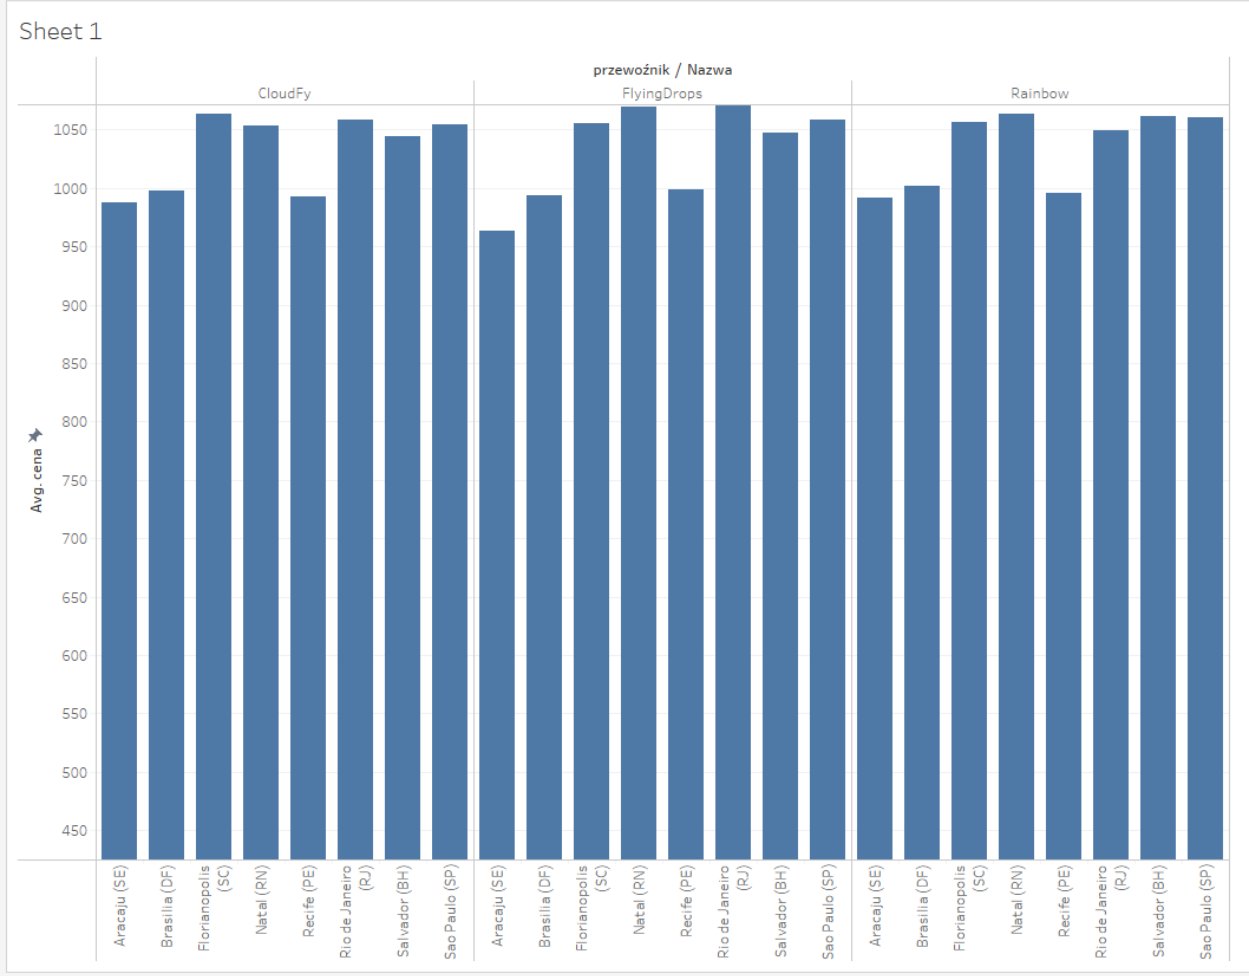

Rysunek 35. Średnia cena lotu z Campo Grande w zależności od nazwy przewoźnika oraz miejsca docelowego

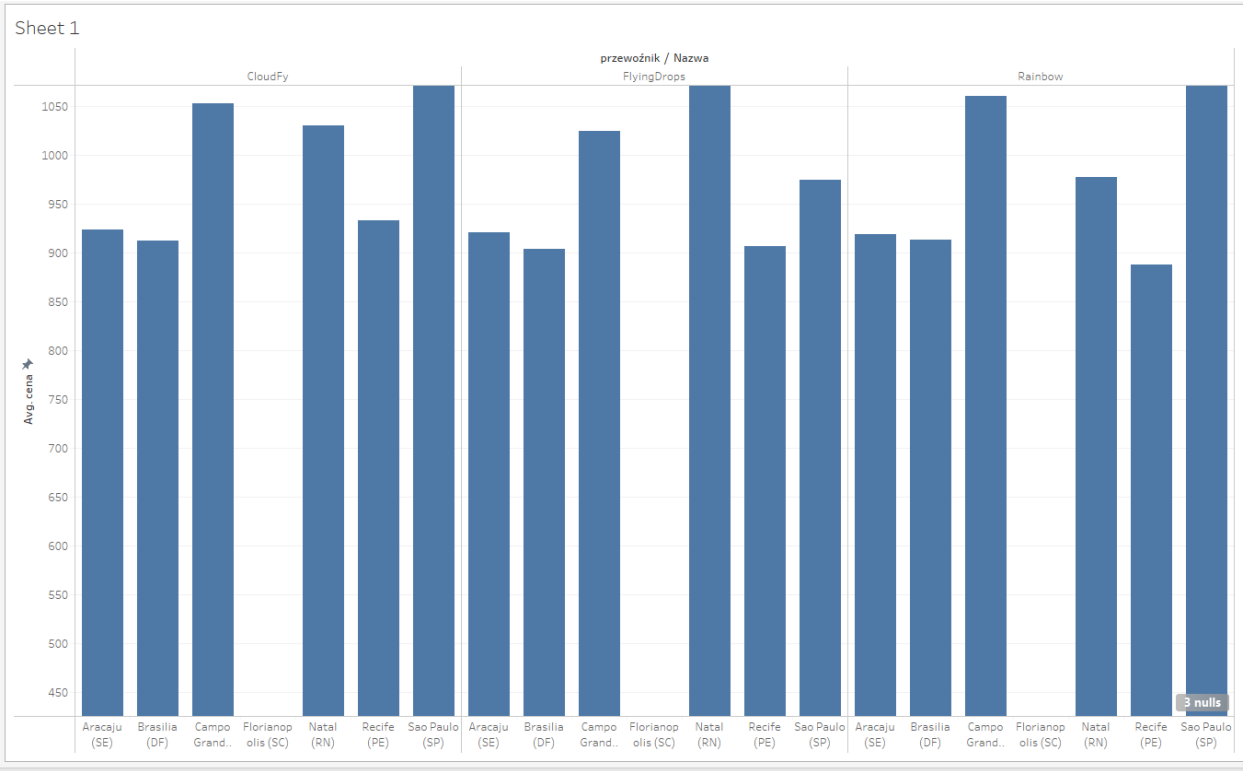

Rysunek 36. Średnia cena lotu z Rio de Janeiro w zależności od nazwy przewoźnika oraz miejsca docelowego

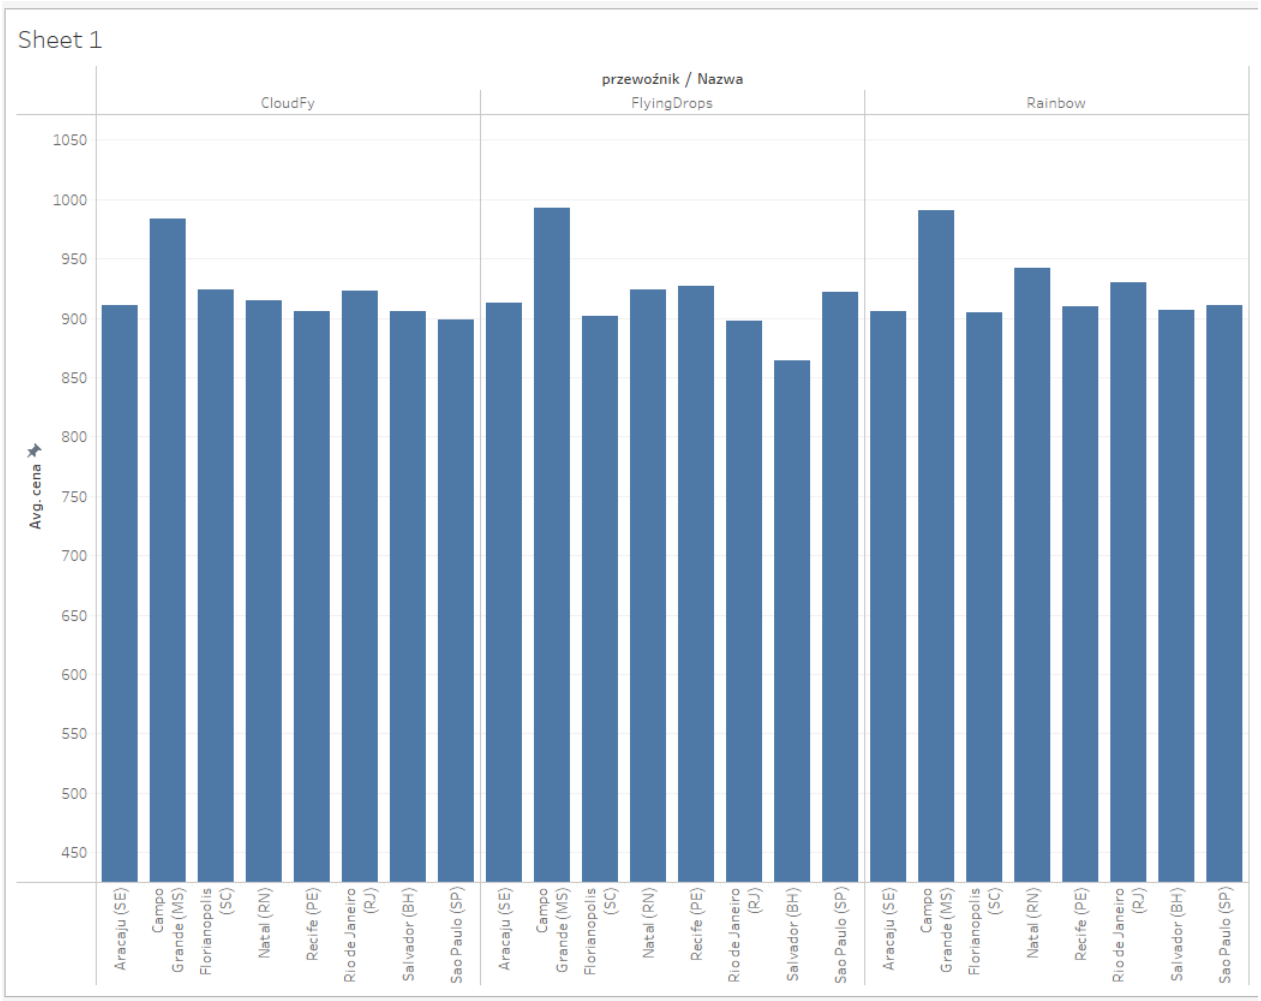

Rysunek 37. Średnia cena lotu z Brasilia w zależności od nazwy przewoźnika oraz miejsca docelowego

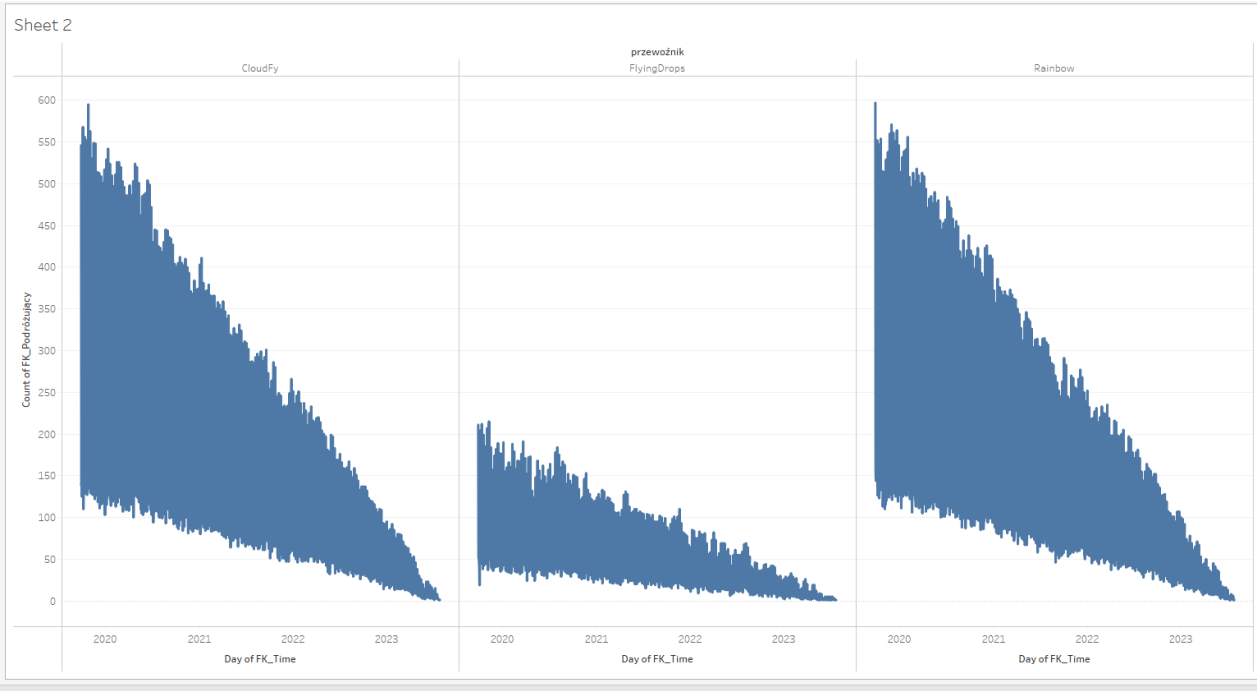

Rysunek 38. Liczba podróżujących w zależności od nazwy przewoźnika i dnia

Liczba podróżujących z roku na rok maleje niezależnie od przewoźnika co widać na rys. 38.

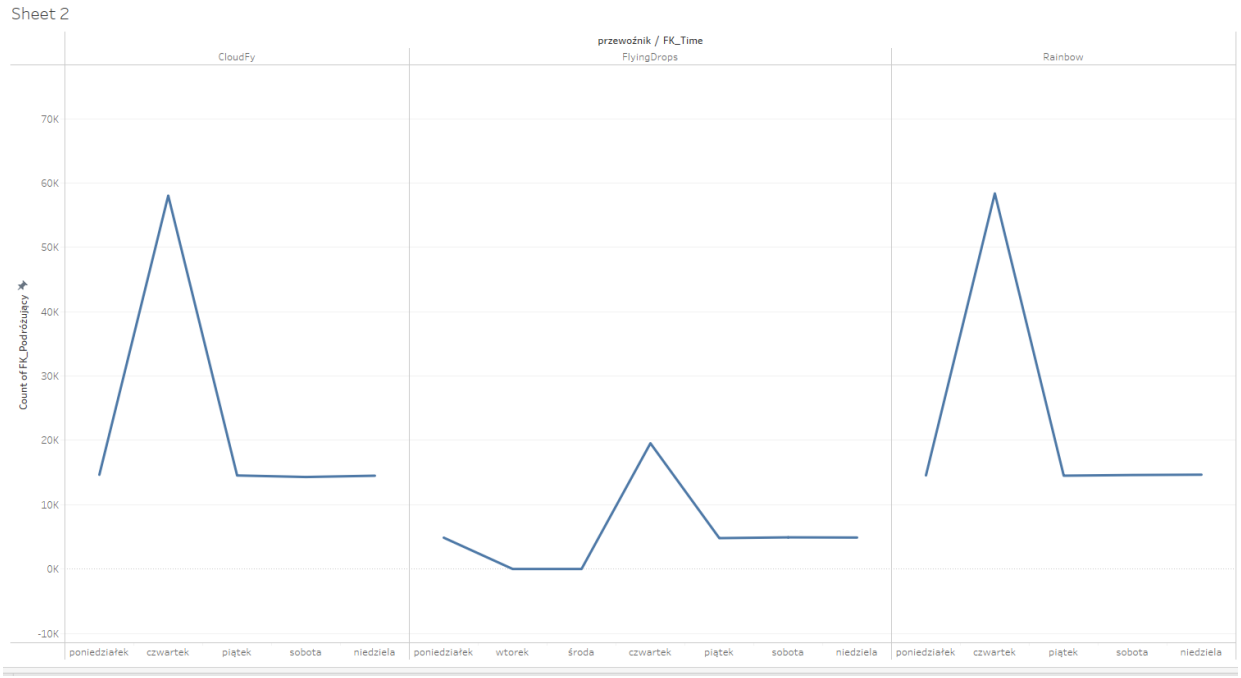

Rysunek 39. Liczba podróżujących w zależności od nazwy przewoźnika i dnia tygodnia

Liczba podróżujących w czwartek jest największa niezależnie od przewoźnika co widać na rys. 39. W końcówce tygodnia, czyli dniach piątek, sobota niedziela oraz na początku tygodnia, czyli w poniedziałek liczba podróży samolotem jest podobna. Najmniej podróży ma miejsce w środku tygodnia, czyli w środku tygodnia pracy (źródło 2).

7.2. Podsumowanie - wnioski z analizy

Analiza danych miała pomóc w znalezieniu odpowiedzi na następujące pytania:

- Dokąd najczęściej odbywają się podróże?
  Do Florianopolis.

- Jakim przewoźnikiem odbywa się lot?
  Mamy do czynienia z 3 przewoźnikami Rainbow, CloudFy, FlyingDrops. Rainbow oraz CloudFy są zdecydowanie częściej wybierane od FlyingDrops.

- Jaka jest klasa miejsca w czasie lotu?

Podróżujący wybierają najczęściej pierwszą klasę. Przewaga pierwszej klasy jest dość wyraźna nad kolejno wybieranymi klasami premium i ekonomiczną.

- W jakich hotelach odpoczywają podróżujący?
  Podróżujący odpoczywają w jednym z dziewięciu hoteli, najczęściej w hotelu K w Salvadorze oraz CB w Rio de Janeiro, a najrzadziej w hotelu A w Florianopolis.

- Kiedy najczęściej odbywają się podróże?
  W polskich miesiącach zimowych (brazylijskie lato). W 2020 roku miało miejsce najwięcej podróży.

Przeprowadzona analiza pozwoliła odpowiedzieć na postawione pytania, a także na wiele innych w tym m.in. dowiedzieliśmy się że do podróży najczęściej dochodzi w czwartek.

8. Wnioski końcowe z realizacji projektu

8.1. Problemy

Podczas realizacji projektu spotkałem się z dwoma większymi problemami, które dotyczyły stworzenia wielowymiarowego modelu analitycznego na poziomie konceptualnym oraz procesu ETL. Właściwe rozdzielenie atrybutów do odpowiednich tabel okazało się kluczowe do stworzenia kostki. Jeśli chodzi o proces ETL to nie było to proste zadanie, wymagało sporo nakładu pracy, często pojawiały się nieoczekiwane błędy.

8.2. Pozyskana wiedza i doświadczenie

Tworząc projekt nauczyłem się sporo nowego, przede wszystkim ETLa, definiowania faktów i wymiarów, tworzenia kostki oraz analizować dane.
Do wykresów nie zastosowałem narzędzia Microsoftu którym jest Excel, lecz wykorzystałem Tableau, które pozwala tworzyć różnego rodzaju czytelne i ciekawe wykresy w dość intuicyjny sposób.

9. Źródła informacji użyte w etapie analizy danych

Aby lepiej przeanalizować sporządzone wykresy korzystałem z następujących źródeł:

1. Źródło informacji dotyczących klimatu w Brazylii https://www.wakacje.pl/pogoda/brazylia/

2. Źródło informacji dotyczących dni roboczych w Brazylii https://marketfinder.thinkwithgoogle.com/intl/pl_pl/guide/brazil-localisation-guide